

ESTADÍSTICA Y PROBABILIDADES PARA INGENIERÍA - BAIN-091

UNIDAD 1: ANÁLISIS DESCRIPTIVO DE DATOS EN INGENIERÍA

PROF. DR. LUIS SÁNCHEZ

VALDIVIA, SEGUNDO SEMESTRE 2023

- 1 CONCEPTOS PRELIMINARES
- 2 ORGANIZACIÓN Y PRESENTACIÓN DE LOS DATOS
- 3 RESÚMENES NUMÉRICOS

CONCEPTOS PRELIMINARES

¿Qué es la Estadística?

La Estadística se ocupa de las técnicas para recolectar, organizar y analizar datos, con el propósito de establecer conclusiones fundamentadas en éstos.

Dos grandes ramas de la Estadística:

- *Estadística Descriptiva*: procedimientos empleados para organizar y resumir conjuntos de observaciones en forma cuantitativa.
- *Estadística Inferencial*: métodos empleados para inferir algo acerca de una población basándose en los datos obtenidos a partir de una muestra.

Elementos de un problema estadístico

- La población de interés y el procedimiento científico que se empleó para muestrear la población.
Variable de estudio. Población. Tipos de muestreo.
- La muestra y el análisis matemático de su información.
Tablas. Estadígrafos. Gráficos. Cálculos.
- Las inferencias estadísticas que resulten del análisis de la muestra.
Estimación. Intervalos de confianza. Pruebas de hipótesis.
Conclusiones.
- La probabilidad de que las inferencias sean correctas.
Niveles de confianza y error.

Conceptos relacionados a población y muestra

- *Población*: Es el conjunto de todos los elementos que cumplen ciertas propiedades y entre los cuales se desea estudiar un determinado fenómeno. Ejemplos: hogares de Valdivia, tornillos producidos por una fábrica en un año, casas de una ciudad, entidades financieras, etc.
- *Muestra*: Es el subconjunto de la población que es estudiado y de la cual se extraen conclusiones hacia la población. La muestra debe ser representativa (las conclusiones obtenidas deben servir para el total de la población).
- *Individuo*: Cada uno de los elementos de la muestra o de la población. Por ejemplo, si la población son los hogares en Valdivia, cada hogar valdiviano representa un individuo.

Conceptos ligados a la definición estadística del problema

- *Variable*: Característica de los elementos de una población que varía de un individuo a otro (salario, color de ojos, sexo, número de hijos, nivel educacional, etc.).
- *Los datos*: Son los valores que alcanzan las variables en las unidades observadas.
- *Parámetro*: Es una característica de la población, tiene un valor fijo y generalmente se busca conocer o estimar.
- *Estadígrafo o estadístico*: Es una función definida sobre los valores de una muestra. Se usa a menudo para “estimar” un parámetro y resumir las características en la muestra.

Ejemplo: la media muestral, $\bar{X}_n = \frac{X_1 + X_2 + \cdots + X_n}{n}$.

Datos de corte transversal y series de tiempo

Datos de sección o corte transversal: Son los obtenidos en el mismo o aproximadamente el mismo momento (punto en el tiempo).

Datos de series de tiempo: Son datos obtenidos a lo largo de varios periodos o instantes.




Figura: Ejemplo datos de serie de tiempo

Clasificación de variables (según escala de medida)

- *Nominal*: Cuando el dato de una variable es una etiqueta o un nombre que identifica un atributo de un elemento. Las etiquetas no tienen orden ni jerarquía.
Ejemplos: género, ocupación (trabajador-cesante), el tipo de escuela a la que se asiste (privada-pública), la provincia o el estado de nacimiento.
- *Ordinal*: Si los datos de la variable muestran las propiedades de los datos nominales y además tiene sentido el orden o jerarquía.
Ejemplos: posición jerárquica en la empresa, percepción de sabores respecto a un platillo, grado satisfacción laboral, nivel socio-económico.

Clasificación de variables (según escala de medida)

- *De intervalos:* Si los datos tienen las características de los datos ordinales y el intervalo entre valores se expresa en términos de una unidad de medición fija.
Ejemplos: la temperatura medida en una escala Fahrenheit o Celsius, las calificaciones en una prueba de aptitudes escolares.
- *De razón:* Además de tenerse todas las características de datos de intervalos, el cero es real y absoluto (no es arbitrario). Cero absoluto implica que hay un punto en la escala donde está ausente o no existe el atributo medido.
Ejemplos: la exposición a la televisión (en minutos), el número de hijos, las ventas de un producto, los metros cuadrados de construcción, la velocidad, la distancia.

Clasificación de variables (según su naturaleza)

- *Cualitativas o categóricas*: aquellas que no aparecen en forma numérica, sino como categorías o atributos (sexo, profesión, color del cabello, nivel educacional, etc.)
- *Cuantitativas*: aquellas que toman valores que pueden expresarse numéricamente (temperatura, salario, número de tornillos fabricados, estatura, etc.).
 - *Discretas*: Son aquellas que toman valores enteros (número de hijos, número de clientes, etc.)
 - *Continuas*: Son aquellas que toman valores en un intervalo de la recta real (altura, velocidad, temperatura, etc.)

Elementos de una variable: nombre, definición, categorías o rango, categorización.

Ejemplo: variable *estado civil*

- Nombre: estado civil
- Definición: Situación civil en relación con las leyes y costumbres el país.
- Categorías: soltero(a); casado(a); viudo(a); divorciado(a).
- Categorización: ¿cuál es su estado civil?

Fuentes de datos estadísticos

Fuentes primarias: La información deberá recolectarse y analizarse. Algunas formas de recolectar datos de “primera mano” es mediante registros, diseño de experimentos, encuestas (muestrales, censales), etc.

Fuentes secundarias: Se pueden encontrar datos (estadísticas) relacionadas en artículos publicados, tesis, revistas, periódicos, etc.

ORGANIZACIÓN Y PRESENTACIÓN DE LOS DATOS

Distribución de frecuencias

La distribución de frecuencias es la representación estructurada, en forma de tabla o gráfica, asociada a la cantidad de veces que la variable de estudio toma un determinado valor o “cae” dentro de un rango de valores.

Tabla de distribución de frecuencias

Para elaborar una tabla de distribución de frecuencias, usualmente se consideran las siguientes definiciones:

- *Frecuencia absoluta de x_i* : número de veces que aparece x_i en el conjunto de datos.
- *Frecuencia relativa de x_i* : Cuociente entre la frecuencia absoluta de x_i y el número total de observaciones.

Tabla de distribución de frecuencias

- *Frecuencia acumulada de x_i* : Suma de todas las frecuencias absolutas de valores menores o iguales a x_i .
- *Frecuencia relativa acumulada de x_i* : Cuociente entre la frecuencia acumulada de x_i y el número total de datos.

Observación: Estos cuatro conceptos se presentan en tablas de frecuencias para variables discretas y continuas. Cuando aparecen demasiados valores distintos en la muestra para una variable usualmente se agrupan en intervalos, llamados *clases*.

Observación: Los conceptos de frecuencia acumulada y frecuencia acumulada relativa no se presentan en una tabla para una variable categórica.

Ejemplo (Tabla de frecuencia para variable discreta con pocos valores)

Supongamos que la muestra consiste de $n = 25$ observaciones de la variable “número de hijos en el hogar” tomadas en Valdivia. Las observaciones recolectadas son:

1, 2, 1, 1, 3, 4, 3, 5, 1, 2, 2, 3, 5, 2, 2, 0, 1, 1, 3, 2, 3, 3, 4, 1, 5.

Valor	Frecuencia absoluta		Frecuencia relativa	
	Simple	Acumulada	Simple	Acumulada
0	1	1	0.04	0.04
1	7	8	0.28	0.32
2	6	14	0.24	0.56
3	6	20	0.24	0.8
4	2	22	0.08	0.88
5	3	25	0.12	1
	25		1	

Ejemplo (Tabla de frecuencia para variable categórica)

Supongamos ahora que la muestra consiste de 15 observaciones de la variable “estado civil” tomadas en Frutillar. Las observaciones recolectadas son:

soltero(a), soltero(a), separado(a), casado(a), viudo(a), soltero(a), separado(a), casado(a), casado(a), casado(a), separado(a), soltero(a), separado(a), separado(a), casado(a).

Valor	Frecuencia absoluta simple	Frecuencia relativa simple
soltero(a)	4	0.26
casado(a)	5	0.33
viudo(a)	1	0.06
separado(a)	5	0.33
	15	1

Ejercicio

Construya una tabla de distribución de frecuencias para la variable correspondiente al número de trabajadores por empresa, en una muestra de 20 empresas pequeñas de la Región de Los Ríos:

6, 5, 4, 4, 6, 2, 5, 3, 3, 4, 4, 4, 6, 3, 5, 5, 4, 5, 4, 3.

Encuentre además:

- 1 La frecuencia absoluta de 4.
- 2 La frecuencia acumulada de 5.
- 3 La frecuencia relativa de 5.
- 4 La frecuencia relativa acumulada de 4.
- 5 El porcentaje de las empresas que tiene 3 o menos trabajadores.

Ejemplo (Tabla de frecuencias para variable continua)

Supongamos que se han recolectado 71 observaciones de la cantidad de horas de estudio por semana por estudiante en una cierta universidad. Los datos fueron agrupados en clases y la tabla de distribución de frecuencias correspondientes es la que se indica a continuación:

Valor	Frecuencia absoluta		Frecuencia relativa	
	Simple	Acumulada	Simple	Acumulada
[10.0, 14.0[	12	12	0.16	0.16
[14.0, 18.0[	18	30	0.25	0.42
[18.0, 22.0[	17	47	0.36	0.66
[22.0, 26.0[	10	57	0.14	0.80
[26.0, 30.0[	8	65	0.11	0.91
[30.0, 34.0[	6	71	0.08	1
	71		1	

Ejemplo: Supongamos que tenemos las siguientes observaciones sobre los precios de venta de 80 autos vendidos en marzo de 2006 en Valdivia (US\$):

20.197	20.372	17.454	20.591	14.968	17.356	18.442	18.722	23.651	24.453
14.266	15.021	25.683	27.872	16.766	17.633	17.962	19.845	16.587	20.269
32.851	16.251	17.047	21.285	26.076	29.492	15.890	18.740	21.324	21.609
25.670	12.546	12.935	16.873	22.449	25.337	17.642	20.613	22.251	22.277
25.034	21.533	24.443	16.889	19.442	14.891	17.818	23.237	17.004	14.357
17.155	16.688	20.657	23.613	16.331	19.817	21.220	27.655	17.895	17.203
20.765	22.783	23.661	29.277	23.285	24.896	17.445	18.556	17.642	18.981
21.052	22.799	12.794	15.263	19.374	21.571	18.639	21.296	33.625	14.399

Observación: ¿Cuántos intervalos o clases deben considerarse para agrupar los datos?

Regla de Sturges (1926):

$$\text{Número de clases} = \lceil 1 + 3.3 \log(n) \rceil,$$

donde $\lceil u \rceil$ corresponde al entero más pequeño no inferior a u y n es el número de observaciones.

Con esto, se tiene que:

- Amplitud de clase $= \frac{\text{Valor máximo} - \text{Valor mínimo}}{\text{Número de clases}}$
- Marca de clase $i = \frac{\text{Límite inferior } i + \text{Límite superior } i}{2}.$

Siguiendo la regla de Sturges, la tabla de distribución de frecuencia tendría 8 clases y es presentada a continuación:

Valor	Frecuencia absoluta		Frecuencia relativa	
	Simple	Acumulada	Simple	Acumulada
[12.421, 15.113)	9	9	0.11	0.11
[15.113, 17.806)	19	28	0.24	0.35
[17.806, 20.498)	16	44	0.20	0.55
[20.498, 23.191)	17	61	0.21	0.76
[23.191, 25.883)	12	73	0.15	0.91
[25.883, 28.576)	3	76	0.04	0.95
[28.576, 31.269)	2	78	0.03	0.97
[31.269, 33.961)	2	80	0.03	1
	80		1	

Note que la amplitud de clase es 2.6 (aprox.) y, por ejemplo, la marca de clase del primer intervalo es 13.8 (aprox.).

Gráficos de distribución de frecuencias (variables categóricas o discretas con pocos valores distintos)




Figura: Gráfico de barras

Gráficos de distribución de frecuencias (variables categóricas o discretas con pocos valores distintos)




Figura: Gráfico de barras

Gráficos de distribución de frecuencias (variables categóricas o discretas con pocos valores distintos)




Figura: Gráfico circular

Gráficos de distribución de frecuencias (variables continuas o discretas con muchos valores distintos)




Figura: Histograma

Gráficos de distribución de frecuencias (variables continuas o discretas con muchos valores distintos)




Figura: Histograma de frecuencia acumulada

Gráficos de distribución de frecuencias (variables continuas o discretas con muchos valores distintos)




Figura: Polígono de frecuencia absoluta

Gráficos de distribución de frecuencias (variables continuas o discretas con muchos valores distintos)




Figura: Polígono de frecuencia acumulada (ojiva)

Ejercicio: La duración de fallas eléctricas, en minutos, se presenta en la siguiente tabla:

22	18	135	15	90	78	69	98	102
83	55	28	121	120	13	22	124	112
70	66	74	89	103	24	21	112	21
40	98	87	132	115	21	28	43	37
50	96	118	158	74	78	83	93	95

- 1 Realice una tabla de frecuencia absoluta donde el límite inferior de la primera clase sea 0 y la amplitud de clase sea 25.
- 2 Realice un polígono de frecuencia absoluta y absoluta acumulada.
- 3 Obtenga el porcentaje de observaciones mayores a 113 minutos.

RESÚMENES NUMÉRICOS

Estadígrafos de posición

Los estadígrafos de posición son de dos tipos:

- *Estadígrafos de posición central (o de tendencia central)*: son valores que permiten tener una medida de un valor central en torno al cual están concentrados los datos. Los más utilizados son:
 - La Media Muestral: el promedio aritmético.
 - La Moda Muestral: el valor más común.
 - La Mediana Muestral: el valor central.
- *Estadígrafos de posición no centrales (o simplemente de posición)*: son medidas que informan de cómo se distribuyen los demás valores de la serie de datos. Generalmente se conocen como *cuantiles*.

La Media Muestral o Media Aritmética

Sean $x_1, x_2, \dots, x_n$ las n -observaciones de una cierta muestra. Se define la Media Muestral, denotada por $\bar{x}$ como

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{\sum_{i=1}^n x_i}{n} \quad (1)$$

Ejemplo: Los siguientes son los puntajes (0 a 100) en el Examen de Estadística de 12 alumnos: 86, 79, 92, 84, 69, 88, 91, 83, 96, 78, 82, 85. La media es

$$\begin{aligned} \bar{x} &= \frac{86 + 79 + 92 + 84 + 69 + 88 + 91 + 83 + 96 + 78 + 82 + 85}{12} \\ &\approx 84.12 \text{ puntos.} \end{aligned}$$

La Mediana Muestral

Supongamos que hemos ordenado las observaciones de una muestra de tamaño n en orden creciente. Tenemos dos posibilidades: o n es par o n es impar. La Mediana Muestral, denotada por m_e , se define como el valor de la muestra que ocupa la posición central en esta ordenación (si n es impar), o bien como el promedio de las dos observaciones centrales (cuando n es par.)

Ejemplo: Para los datos de los puntajes de los estudiantes del ejemplo anterior, primero realizamos la ordenación de menor a mayor. Esto nos entrega la muestra ordenada

69, 78, 79, 82, 83, 84, 85, 86, 88, 91, 92, 96.

Note que como $n = 12$ es par, tendremos dos posiciones centrales.

Las observaciones que las ocupan son 84 y 85. Luego,

$$m_e = \frac{84 + 85}{2} = 84.5 \text{ puntos.}$$

Ejemplo: Supongamos ahora que tenemos las notas de 5 estudiantes de Ingeniería. Estas son: 4.3, 5.5, 3.6, 6.5, 5.8.

La muestra ordenada de menor a mayor es: 3.6, 4.3, 5.5, 5.8, 6.5.

Como $n = 5$ es impar, hay una sola observación que ocupa la posición central, ésta es: 5.5. Luego, $m_e = 5.5$.

Observación: Note que la mediana divide la lista de observaciones en dos con la misma cantidad de observaciones. En una de ellas todas sus observaciones son menores o iguales a m_e , y en la otra todas sus observaciones son mayores o igual es a m_e .

La Moda Muestral

La Moda Muestral, denotada por m_o , corresponde a un valor de la muestra que tiene la mayor frecuencia absoluta. De lo anterior, puede ocurrir que tengamos más de una moda.

Ejemplo: Consideremos la muestra del número de hijos de hogares en Valdivia. Los datos eran:

1, 2, 1, 1, 3, 4, 3, 5, 1, 2, 2, 3, 5, 2, 2, 0, 1, 1, 3, 2, 3, 3, 4, 1, 5.

Al observar notamos que el valor más repetido es 1, que se repite 7 veces. Luego, $m_o = 1$.

Algunos comentarios sobre medidas de tendencia central

- La media es el estadístico de tendencia central más utilizado.
- La media muestral es el único estadígrafo de posición tal que “la suma de las desviaciones de cada valor respecto a la media es cero”, es decir,

$$\sum_{i=1}^n (x_i - \bar{x}) = 0.$$

- La media es muy sensible a los valores extremos. Se desplaza en la dirección del valor extremo. Por tanto, en tales casos, pierde significativamente su cualidad de ser un valor en torno al cual están concentrados los datos. Así, no se recomienda usar como medida central en distribuciones muy *asimétricas*. En su lugar, la mediana es una mejor opción.

Cuantiles Muestrales

Note que la mediana cumple que *al menos* el 50 % de los datos es menor o igual a ella.

Sea $q \in (0, 1)$. La idea detrás de un cuantil muestral q es extender el concepto de la mediana muestral, y buscar el valor más pequeño obtenido a partir del conjunto de datos tal que *al menos* $100 \cdot q$ % de los datos sea menor o igual a éste.

Al igual que en el caso de la mediana, si $q \cdot n$ es decimal, entonces tomaremos como cuantil q la observación que está en la posición $\lceil q \cdot n \rceil$. Si por el contrario $q \cdot n$ es entero, queda en discusión qué valor tomar como el cuantil q , pero siguiendo la idea usada en la mediana, se podría considerar el promedio de los datos que están en la posición $q \cdot n$ y $q \cdot n + 1$.

Ejemplo: Supongamos que tenemos los siguientes datos:

1, 6, 8, 2, 3, 2, 16, 4, 10, 14, 15,

y deseamos obtener el cuantil-0.5.

Si ordenamos los datos de menor a mayor, obtenemos

1, 2, 2, 3, 4, 7, 8, 10, 14, 15, 16.

Observe que $0.5 \cdot 11 = 5.5$. Luego, como 5.5 no es entero, consideramos como cuantil-0.5 la observación que está en la posición 6, es decir, 7.

Observe que se cumple que al menos el $100 \cdot 0.5 = 50\%$ de los datos es menor o igual a 7.

Existen diferentes tipos de cuantiles:

- Mediana: Valor (m_e) que corresponde al cuantil-0.5
- Cuartiles: 3 valores (c_1, c_2, c_3) que corresponden a los cuantiles 0.25, 0.50 y 0.75.
- Quintiles: 4 valores ($q_1, \dots, q_4$) que corresponden a los cuantiles 0.20, 0.40, $\dots$, 0.80.
- Deciles: 9 valores ($d_1, \dots, d_9$) que corresponden a los cuantiles 0.10, 0.20, $\dots$, 0.90.
- Percentiles: 99 valores ($p_1, \dots, p_{99}$) que corresponden a los cuantiles 0.01, 0.02, $\dots$, 0.99.

Observación: Se cumple que $m_e = c_2 = d_5 = p_{50}$.

Ejemplo: Consideremos nuevamente el ejemplo del número de hijos de 25 hogares de Valdivia. La muestra ordenada es

0, 1, 1, 1, 1, 1, 1, 1, 2, 2, 2, 2, **2**, 2, 3, 3, 3, 3, 3, 3, 4, 4, 5, 5, 5.

Note que como $n = 25$ es impar, hay una única observación central, a saber, $m_e = 2$.

Con respecto a los cuartiles c_1, c_2, c_3 , recordar que $c_2 = m_e$. Para hallar los restantes, realizamos lo siguiente:

Obs	0	1	1	1	1	1	1	1	2	2	2	2	2
Pos	1	2	3	4	5	6	7	8	9	10	11	12	13
Obs	2	3	3	3	3	3	3	4	4	5	5	5	
Pos	14	15	16	17	18	19	20	21	22	23	24	25	

Note que c_3 corresponde al cuantil 0.75. Sabemos además que $n = 25$. Realizamos el cálculo siguiente:

$$\text{Posición aprox.} = 0.75 \cdot 25 = 18.75.$$

Luego, la posición inmediatamente a la derecha de es la 19, por tanto $c_3 = 3$. Observe que al menos un 75 % de los datos son menores o iguales a c_3 .

Con respecto a c_1 , notemos que éste corresponde al cuantil 0.25. Luego,

$$\text{Posición aprox.} = 0.25 \cdot 25 = 6.25.$$

Por tanto, el cuantil 0.25 es la observación que está en la posición 7, es decir, $c_1 = 1$. Al menos el 25 % de las observaciones es menor o igual a c_1 .

¿Cuál sería el valor de p_{80} ?

Note que p_{80} es el cuantil 0.8. Entonces, calculamos $0.8 \cdot 25 = 20$. Como el resultado es entero, ubicamos las observaciones en las posiciones 20 y 21, y obtenemos su promedio

$$p_{80} = \frac{3 + 4}{2} = 3.5.$$

Ejercicio: Obtenga los valores de d_5 , p_{87} , c_2 y el cuantil 0.34 para los datos de los hogares de Valdivia.

Ejercicio: Obtenga los mismos elementos para los datos de los precios de venta de autos vendidos en Valdivia.

Estadígrafos de dispersión

Tienen por objetivo determinar el grado de alejamiento de los datos respecto a un estadígrafo de tendencia central que, generalmente suele ser la media aritmética. Nos dan una idea acerca de lo agrupados que están los datos, y por lo tanto indican la homogeneidad de estos.

Rango

Muestra la amplitud de los valores de la muestra y se calcula como la diferencia entre el valor más elevado y el valor más bajo.

Ejemplo: El rango de los datos de puntajes de alumnos en el Examen de Estadística es:

$$\text{Rango} = |96 - 69| = 27.$$

La Varianza Muestral

Indica el promedio de las desviaciones (al cuadrado) de las observaciones con respecto a la media aritmética. Su expresión matemática para una muestra de observaciones $x_1, \dots, x_n$ es

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (2)$$

Ejemplo: Supongamos que tenemos las alturas (en mts) de cuatro varones: 1.70, 1.74, 1.69 y 1.76. Puede corroborar que la media muestral es: $\bar{x} = 1.72$. Luego,

$$\begin{aligned} s^2 &= \frac{(1.70 - 1.72)^2 + (1.74 - 1.72)^2 + (1.69 - 1.72)^2 + (1.76 - 1.72)^2}{4 - 1} \\ &= 0.001. \end{aligned}$$

La Desviación Estándar

La denotaremos por s y corresponde a la raíz cuadrada de la varianza muestral, es decir, $s = \sqrt{s^2}$.

Ejemplo: Consideremos nuevamente los datos del ejemplo anterior. Notar que

$$s = \sqrt{s^2} = \sqrt{0.001} = 0.03.$$

Observación: Note que la unidad de medida de la desviación estándar es la misma que la de las observaciones. En el ejemplo anterior concluimos que las observaciones se alejan en promedio *aproximadamente* 0.03 mts de la media ($\bar{x} = 1.72$ mts).

Observación: Si la muestra consiste solamente de observaciones que tienen el mismo valor, la varianza muestra y la desviación estandar serán 0.

Rango intercuartílico

El rango intercuartílico, denotado por RIC, está definido como:

$$\text{RIC} = c_3 - c_1.$$

Observación: El RIC es una medida de dispersión recomendada cuando el histograma de datos no es simétrico (forma de campana).

Ejemplo: El RIC para el caso de los datos sobre el número de hijos de hogares en Valdivia es

$$\text{RIC} = |3 - 1| = 2.$$

Podemos decir que el 50 % de las observaciones más centrales están en un rango de longitud 2.

Diagrama de cajas (o boxplot)

Valores atípicos u outliers: Un dato atípico es aquella observación que está muy distante de la mayoría de los datos. Se dice que un valor es un valor atípico si es mayor que

$$c_3 + 1.5\text{RIC} \text{ (valor atípico a la derecha)}$$

o es menor que

$$c_1 - 1.5\text{RIC} \text{ (valor atípico a la izquierda).}$$

El diagrama de cajas es una representación gráfica basada en los cuartiles que ayuda a ilustrar un conjunto de datos. Para elaborar el diagrama se requiere: el valor mínimo (sin outliers); c_1 ; la mediana (c_2); c_3 ; el valor máximo (sin outliers); y outliers






Figura: Diagrama de cajas en R

El diagrama de cajas para los ejemplos del número de hijos de hogares y los montos por autos vendidos en Valdivia son:



¿Qué medidas de posición central y dispersión son mejores?

Cuando queremos describir una variable usamos alguna medida de posición central y una medida de dispersión.

El par de medidas más comúnmente usado es la *media aritmética* y la *desviación estándar*.

Sin embargo, vimos que cuando la distribución de las observaciones es *sesgada (asimétrica)*, la media no es una buena medida de posición central y preferimos la *mediana*. La mediana en general va acompañada del *rango* como medida de dispersión. Pero cuando observamos valores extraños (extremos) el rango se ve muy afectado, por lo que preferimos usar el *rango intercuartílico*.

Estadígrafos de forma

El objetivo de los estadígrafos de forma es indicarnos la cantidad de “deformación” que tiene la distribución de los datos respecto de una Distribución Normal Estándar, la cual tiene forma de una campana.






Figura: Campana de Gauss

Mediante estos estadígrafos podemos estudiar las siguientes características:

- *Estadígrafos de asimetría*: Indican si el polígono tiene una forma simétrica, es decir, si respecto al centro del mismo (centro de simetría) los segmentos de recta que quedan a derecha e izquierda son similares.
- *Estadígrafos de curtosis*: Indican si los valores de la distribución están más o menos concentrados alrededor de los valores medios de la muestra (es decir, mide el grado de apuntamiento).

Simetría**Curtosis**

Coeficiente de asimetría de Fisher

Para cuantificar la asimetría de una distribución de datos, el coeficiente de asimetría de Fisher viene dado por

$$As = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{s^3}.$$

- $As = 0 \Rightarrow$ distribución simétrica (misma concentración de valores a la derecha y a la izquierda)
- $As > 0 \Rightarrow$ distribución asimétrica positiva (mayor concentración de valores a la izquierda)
- $As < 0 \Rightarrow$ distribución asimétrica negativa (mayor concentración de valores a la derecha).

Coeficiente de curtosis

Viene dado por la expresión siguiente:

$$K = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{s^4}.$$

- $K = 3 \Rightarrow$ distribución mesocúrtica (grado de concentración de valores en la zona central igual a la de la Distribución Normal Estándar).
- $K > 3 \Rightarrow$ distribución leptocúrtica (elevado grado de concentración alrededor de los valores centrales de la variable).
- $K < 3 \Rightarrow$ distribución platicúrtica (reducido grado de concentración alrededor de los valores centrales de la variable).

Ejemplo: El cálculo de los dos coeficientes anteriores para los datos de las alturas son:

$$\begin{aligned} A_s &= \frac{(1.70 - 1.72)^3 + (1.74 - 1.72)^3 + (1.69 - 1.72)^3 + (1.76 - 1.72)^3}{4 \cdot 0.03^3} \\ &= 0.086 \end{aligned}$$

$$\begin{aligned} K &= \frac{(1.70 - 1.72)^4 + (1.74 - 1.72)^4 + (1.69 - 1.72)^4 + (1.76 - 1.72)^4}{4 \cdot 0.03^4} \\ &= 0.72 \end{aligned}$$

Se concluye que los datos presentan distribución platicúrtica y con muy leve asimetría positiva.

Algunas medidas descriptivas para datos agrupados

En algunas ocasiones solo se tienen datos agrupados en una distribución de frecuencias. Por ejemplo, considere, la tabla siguiente presenta la distribución de las duraciones en días en una muestra de auditorías de fin de año de una empresa pequeña de contadores públicos.

Duración de la auditoría (en días)	Frecuencia
10–14	4
15–19	8
20–24	5
25–29	2
30–34	1
Total	<u>20</u>

¿Cómo obtendríamos, por ejemplo, la media, mediana, moda, percentiles y varianza muestrales para estos datos?

Observación: Al no contar con las observaciones individuales necesariamente hay pérdida de información. Esto significa que solo podremos intentar una aproximación a las medidas descriptivas verdaderas de la muestra.

Media muestral

$$\bar{x} = \frac{\sum_{i=1}^k c_i f_i}{n} = \frac{c_1 \cdot f_1 + c_2 \cdot f_2 + \cdots + c_k \cdot f_k}{n}, \quad (3)$$

donde

- k es el número de clases; n es el total de observaciones;
- c_i es la marca de la clase i ; f_i es la frecuencia absoluta de la clase i .

En el caso de nuestro ejemplo, tenemos $c_1 = 12$, $c_2 = 17$, $c_3 = 22$, $c_4 = 27$ y $c_5 = 32$. Luego, el cálculo es

$$\bar{x} = \frac{12 \cdot 4 + 17 \cdot 8 + \cdots + 32 \cdot 1}{20} = 19.$$

Mediana muestral

$$m_e = L_i + \left(\frac{\frac{n}{2} - F_{i-1}}{f_i} \right) \cdot A_i, \quad (4)$$

donde

- i es el intervalo donde se tiene la menor frecuencia absoluta acumulada mayor o igual a $n/2$;
- f_i es la frecuencia absoluta del intervalo i ;
- F_{i-1} es la frecuencia absoluta acumulada anterior al intervalo i ;
- A_i y L_i son la amplitud y límite inferior del intervalo i , respectivamente.

En el caso de nuestro ejemplo, $n/2 = 10$. Observamos que el intervalo i es 15-19. Tenemos:

$$L_i = 15; F_{i-1} = 4; f_i = 8; A_i = 4.$$

Luego,

$$m_e = 15 + \left(\frac{10 - 4}{8} \right) \cdot 4 = 18.$$

Moda muestral

$$m_o = L_i + \left(\frac{f_i - f_{i-1}}{(f_i - f_{i-1}) + (f_i - f_{i+1})} \right) \cdot A_i, \quad (5)$$

donde i corresponde al intervalo que tiene la mayor frecuencia absoluta, y los demás elementos se definen en base a éste.

En nuestro ejemplo, para el cálculo de la moda, el intervalo i corresponde a 15-19. Tenemos:

$$L_i = 15; f_i = 8, f_{i-1} = 4, f_{i+1} = 5; A_i = 4.$$

Entonces,

$$m_o = 15 + \left(\frac{8 - 4}{(8 - 4) + (8 - 5)} \right) \cdot 4 = 17.29.$$

Percentiles muestrales

$$p_m = L_i + \left[\frac{\left(\frac{m}{100}\right) \cdot n - F_{i-1}}{f_i} \right] \cdot A_i, \quad (6)$$

donde m es el número de percentil (entero entre 1 y 99) y i es el intervalo donde se tiene la menor frecuencia absoluta acumulada mayor o igual a $(m/100) \cdot n$.

En el caso de nuestro ejemplo, si quisieramos obtener el percentil 33, tendríamos $m = 33$ y el intervalo i sería 15-19. Tendríamos,

$$L_i = 15; F_{i-1} = 4; f_i = 8; A_i = 4.$$

Por lo tanto,

$$p_{33} = 15 + \left(\frac{6.6 - 4}{8} \right) \cdot 4 = 16.3.$$

Varianza muestral

$$S^2 = \frac{\sum_{i=1}^k f_i (c_i - \bar{x})^2}{n - 1}. \quad (7)$$

El valor de la varianza muestral para nuestro ejemplo es

$$S^2 = 30.$$

Observación: Cuando existen intervalos no acotados en la tabla de frecuencias para datos agrupados, no tenemos manera de obtener las *todas* las marcas de clase y por tanto, la fórmula para la media y la varianza no pueden ser aplicadas. Además, esto puede dificultar el cálculo de otras medidas numéricas como los percentiles o la moda.