

ESTADÍSTICA Y PROBABILIDADES PARA INGENIERÍA - BAIN-091

UNIDAD 4: ANÁLISIS DE LAS RELACIONES ENTRE VARIABLES DEL ÁMBITO DE LA INGENIERÍA

PROF. DR. LUIS SÁNCHEZ

VALDIVIA, SEGUNDO SEMESTRE 2023

CONTENIDOS

- 1 INTRODUCCIÓN
- 2 ESTIMACIÓN DE COEFICIENTES DE REGRESIÓN
- 3 SUPUESTOS DEL MODELO Y SU IMPORTANCIA
- 4 INTERVALOS DE CONFIANZA
- 5 PRUEBAS DE HIPÓTESIS
- 6 INTERPRETACIÓN DE LOS COEFICIENTES DE REGRESIÓN
- 7 COEFICIENTE DE DETERMINACIÓN
- 8 EVALUACIÓN DE LOS SUPUESTOS

INTRODUCCIÓN

Nuestro objetivo será estudiar o describir la **relación entre una variable aleatoria** Y (llamada variable respuesta) y otra variable X (llamada variable predictora).

Suponga que Y corresponde al salario de un ingeniero en Valdivia, y X el número de años que han transcurrido desde su graduación.

Es claro que podemos tener distintos salarios tomando un grupo de individuos con la misma cantidad de años transcurridos desde su graduación:

$$X = x \longrightarrow y_1, y_2, \dots$$

En otras palabras, Y se puede considerar una v.a. para cada valor fijo x de X .

Luego, *para cada* número de años transcurridos desde la graduación x , podemos obtener la media del salario para ese nivel de años transcurridos

$$E(Y \mid X = x).$$

Lo anterior puede escribirse mediante la relación

$$E(Y \mid X = x) = f(x), \quad (1)$$

donde f es una función real, es decir, la media condicional de Y dado $X = x$ es una función de x .

Otra manera de leer la expresión (1) es: para cada valor x de X , tenemos una media de Y .

Para cada valor x , Y puede escribirse como su media $E(Y | X = x)$ más una perturbación aleatoria ϵ , es decir,

$$Y = f(x) + \epsilon. \quad (2)$$

La ecuación dada en (1), o su forma alternativa dada en (2), corresponde a un **modelo de regresión**.

Si se asume que

$$f(x) = \beta_0 + \beta_1 x,$$

donde β_0 y β_1 son números reales fijos (llamados **coeficientes de regresión**), entonces tenemos el usual **modelo de regresión lineal simple**

$$Y = \beta_0 + \beta_1 x + \epsilon, \quad (3)$$

o equivalentemente,

$$E(Y | X = x) = \beta_0 + \beta_1 x \quad (4)$$

En general, partiremos desde un conjunto de datos

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n),$$

(es decir, observaciones de las variables X e Y), y buscaremos escoger o estimar tales coeficientes de regresión.

Note que de esta forma tendríamos una expresión para **estimar** la media de Y dado un valor particular x de X .

Por ejemplo, si obtuvieramos las estimaciones $\hat{\beta}_0 = 1100000$ y $\hat{\beta}_1 = 70000$, tendríamos el modelo (estimado)

$$\hat{E}(Y | X = x) = 1100000 + 70000 \cdot x.$$

Si quisieramos saber cuanto gana en promedio un ingeniero a los 7 años de egresado, lo estimaríamos como $1100000 + 70000 \cdot 7 = \1590000 .

Algunas consideraciones previas

Conjunto de datos

Usualmente nuestros datos muestrales estarán presentados en una tabla donde en las columnas van los valores de las variables y cada fila corresponde a los valores de esas variables para un individuo en específico.

Para el ejemplo anterior supongamos los siguientes datos:


X : número de años	Y : salario
3	1250000
2	1200000
2	1230000
6	1540000
1	1180000
3	1290000
5	1500000
8	1645000

Note que los individuos no necesitan mostrarse en ningún orden en particular. En la tabla se aprecia que para una misma cantidad de años se pueden tener distintos salarios pues son individuos diferentes.

En regresión lineal, lo primero es investigar si existe relación entre la media condicional de Y y X . Esto usualmente se puede llevar mediante dos herramientas.

Diagrama de dispersión (scatter-plot)

La representación gráfica de este tipo de variables es en realidad semejante a la representación de puntos en el plano, usando unos ejes de coordenadas. Cada pareja de valores da lugar a un punto en el plano y el conjunto de puntos que se obtiene se denomina “diagrama de dispersión o nube de puntos”.



En el caso de apreciarse una tendencia ascendente, decimos que hay una relación positiva; mientras que si la tendencia es descendente decimos que hay una dependencia negativa.




Figura: distintos tipos de diagramas de dispersión

Correlación entre dos variables

El coeficiente de correlación lineal de Pearson entre dos variables X e Y , denotado por r_{xy} , está dado por

$$r_{xy} = \frac{n \sum x_i y_i - \sum x_i \sum y_i}{\sqrt{n \sum x_i^2 - (\sum x_i)^2} \sqrt{n \sum y_i^2 - (\sum y_i)^2}}. \quad (5)$$

Aquí x_i y y_i corresponden a las observaciones de las variables X e Y para el individuo i .

Este coeficiente nos indica si los puntos tienen una tendencia a disponerse alineadamente, o dicho de otro modo, es útil para determinar si hay relación lineal entre dos variables. No obstante, no servirá para otro tipo de relaciones (cuadrática, logarítmica, etc.). Toma valores entre -1 y 1.


- $r_{xy} \approx 1$ indica una fuerte relación lineal positiva.
- $r_{xy} \approx -1$ indica una fuerte relación lineal negativa.
- $r_{xy} \approx 0$ indica relación lineal débil.
- $r_{xy} = 1$ indica relación lineal positiva perfecta, es decir, todos los puntos caen en una línea recta con pendiente positiva.
- $r_{xy} = -1$ indica relación lineal negativa perfecta, es decir, todos los puntos caen en una línea recta con pendiente negativa.
- $r_{xy} = 0$ indica que no hay relación lineal entre x e y .

Ejemplo: En el caso del ejemplo anterior, su valor es 0.98, lo cual indica una fuerte relación lineal positiva (usar función `cor()` del software R).

Observación: Si el diagrama de dispersión nos entrega una relación lineal positiva o negativa, o bien, el coeficiente de correlación lineal de Pearson nos arroja un valor cercano a -1 o a 1, hay indicios de que existe una relación lineal entre $E(Y | X = x)$ y X , y por tanto, tiene sentido ajustar un modelo de regresión lineal.

ESTIMACIÓN DE COEFICIENTES DE REGRESIÓN

Una de las maneras de estimar los coeficientes de regresión β_0 y β_1 es usar el **método de mínimos cuadrados**. Para ilustrarlo considere la siguiente figura:



Note que las curvas en color rojo son posibles modelos (o alternativas) de $E[Y | X = x]$, cambiando los valores de β_0 y β_1 .

Supongamos que la muestra de observaciones que tenemos de X e Y son los puntos en color azul.

Como nuestro interés es estimar medias condicionales, la recta que atravesase mejor la nube de puntos es un modelo apropiado para adoptar. El calificativo “mejor” alude a que los puntos queden distribuidos de forma más homogénea en torno a la recta.

Note que la distancia vertical del punto (x_i, y_i) a la recta de color rojo (representada en el segmento de color negro) es $|y_i - (\beta_0 + \beta_1 x)|$.

Una manera de encontrar esta recta (modelo más apropiado), es considerar la suma de los cuadrados de las distancias verticales de los puntos (x_i, y_i) a la recta y minimizarla.

En síntesis, el mejor modelo estará dado con aquellos valores de β_0 y β_1 que resuelven

$$\min_{\beta_0, \beta_1} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2.$$

Los valores que resuelven este problema se llaman estimadores por mínimos cuadrados de β_0 y β_1 , denotados por $\hat{\beta}_0$ y $\hat{\beta}_1$.

En la figura anterior, el mejor modelo está representado por la recta en color azul, la cual corresponde a

$$\hat{E}[Y | X = x] = \hat{\beta}_0 + \hat{\beta}_1 x.$$

Existen soluciones analíticas para $\hat{\beta}_0$ y $\hat{\beta}_1$, las cuales corresponden a

$$\begin{aligned}\hat{\beta}_0 &= \frac{\sum_{i=1}^n y_i}{n} - \hat{\beta}_1 \frac{\sum_{i=1}^n x_i}{n} \\ &= \bar{y} - \hat{\beta}_1 \bar{x} \\ \hat{\beta}_1 &= \frac{\sum_{i=1}^n x_i y_i - \frac{(\sum_{i=1}^n x_i)(\sum_{i=1}^n y_i)}{n}}{\sum_{i=1}^n x_i^2 - \frac{(\sum_{i=1}^n x_i)^2}{n}} \\ &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}\end{aligned}$$

Ejemplo: Para el caso del salario de los ingenieros y los años de egresado, las estimaciones por mínimos cuadrados de β_0 y β_1 son 1076329.11 y 74145.57, respectivamente. Tales estimaciones pueden realizarse con el comando `lm()`.

El modelo de regresión ajustado para estos datos es

$$\hat{E}[Y \mid X = x] = 1076329.11 + 74145.5 \cdot x.$$

Si por ejemplo, queremos tener una *estimación* de lo que se espera que gane un ingeniero cuando han transcurrido 7 años desde su graduación, la estimación sería

$$1076329.11 + 74145.5 \cdot 7 = \$1595348.$$

Ejemplo: Considere la base de datos dada en la tabla siguiente

peso (kg)	edad (años)	grasas (mg de triglicéridos/dl)
84	46	354
73	20	190
65	52	405
70	30	263
76	57	451
69	25	302
63	28	288
72	36	385
79	57	402
75	44	365
27	24	209
89	31	290
65	52	346
57	23	254
59	60	395
69	48	434
60	34	220
79	51	374
75	50	308
82	34	220
59	46	311
67	23	181
85	37	274
55	40	303
63	30	244




Figura: Diagrama de dispersión: edad vs grasas




Figura: Diagrama de dispersión con línea de regresión ajustada

$$\hat{E}[Y | X = x] = 102.575 + 5.321x.$$

Por ejemplo, para una edad de 78 años, podemos estimar que en promedio las personas tienen un nivel de grasas de

$$102.575 + 5.321 \cdot 79 = 592.934 \text{ mg de triglicéridos/dl}$$

Observación: A menudo se usa la notación (más simple) $\hat{y}$ para $\hat{E}[Y | X = x]$, debido a que $\hat{E}[Y | X = x]$ sirve como una estimación de Y para un valor x de X .

Por ejemplo, para el modelo anterior podemos escribir:

$$\hat{y} = 102.575 + 5.321x.$$

Otra manera de expresar la interpretación es: “estimamos que un individuo con una edad de 70 años tenga un nivel de grasas de $102.575 + 5.321 \cdot 70 = 475.045$ mg de triglicéridos/dl”.

SUPUESTOS DEL MODELO Y SU IMPORTANCIA

Con el propósito de establecer propiedades estadísticas de los estimadores $\hat{\beta}_0$ y $\hat{\beta}_1$ usualmente se realizan algunos supuestos.

Antes de explicitarlos, recordemos que el modelo de regresión lineal simple puede ser formulado como

$$E[Y | X = x] = \beta_0 + \beta_1 x, \quad Y \text{ v.a. para cada } x, \quad (6)$$

o equivalentemente,

$$Y = \beta_0 + \beta_1 x + \epsilon, \quad \epsilon \text{ v.a. para cada } x \quad (7)$$

Note que el término ϵ es una v.a. para cada valor x de X , y puede ser visto como la diferencia entre Y y la expresión $\beta_0 + \beta_1 x$ (la cual permite obtener $\hat{y}$). Por ello, a ϵ se le llama la componente de error del modelo.

Supuesto 1: (Linealidad en los parámetros) La media condicional de Y sobre X puede ser modelada como

$$E[Y | X = x] = \beta_0 + \beta_1 x, \quad \text{para todo } x$$

Usando la formulación (7), éste supuesto es equivalente a asumir que

$$E[\epsilon | X = x] = 0, \quad \text{para todo } x.$$

Supuesto 2: (Homocedasticidad o varianza constante) Se cumple que

$$V[Y | X = x] = \sigma^2, \quad \text{para todo } x.$$

Esto es equivalente a asumir que

$$V[\epsilon | X = x] = \sigma^2, \quad \text{para todo } x.$$

Supuesto 3: (Independencia) Las v.a. $Y | X = x$ y $Y | X = x'$ son independientes para todo x y x' .

Esto es equivalente a decir que los errores son independientes, es decir, $\epsilon | X = x$ y $\epsilon | X = x'$ son independientes para todo x y x' .

Supuesto 4: (Normalidad) La distribución de Y dado un valor x de X es normal, para todo x .

Esto es equivalente a establecer la normalidad sobre los errores, es decir, asumir que la distribución de ϵ dado un valor x de X es normal, para todo x .




Figura: Ilustración de los supuestos en el modelo de regresión lineal simple

Observación: En general, σ^2 es desconocida y debe ser estimada. Un estimador para σ^2 es

$$\begin{aligned}\hat{S}^2 &= \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - 2}, \quad \hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i, \quad i = 1, \dots, n \\ &= \frac{\sum_{i=1}^n (y_i - \bar{y})^2 - \hat{\beta}_1 \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n - 2}\end{aligned}$$

Teorema de Gauss-Markov

Si se cumplen los Supuestos 1, 2 y 3, entonces los estimadores por mínimos cuadrados β_0 y β_1 satisfacen que:

- Son funciones lineales de las observaciones de Y ;
- Son insesgados, es decir, $E[\hat{\beta}_i] = \beta_i$, para $i = 0, 1$; y
- Tienen varianza mínima dentro de la clase de todos los estimadores lineales insesgados.

Si además se cumple el Supuesto 4, entonces

$$\begin{aligned}\hat{\beta}_0 &\sim N\left(\beta_0, \frac{\sigma^2 \sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2}\right) \\ \hat{\beta}_1 &\sim N\left(\beta_1, \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\right)\end{aligned}$$

Observación: El teorema establece que bajo los Supuestos 1, 2 y 3, los estimadores β_0 y β_1 gozan de excelentes y deseables propiedades estadísticas.

Por otro lado, cuando se añade el supuesto de normalidad, podemos establecer la distribución de los mismos, y con ellos desarrollar intervalos de confianza y pruebas de hipótesis, como veremos.

INTERVALOS DE CONFIANZA

Estimaciones para la desviación estandar de los estimadores $\hat{\beta}_0$ y $\hat{\beta}_1$ son

$$se(\hat{\beta}_0) = \sqrt{\frac{\hat{s}^2 \sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2}}, \quad y \quad se(\hat{\beta}_1) = \sqrt{\frac{\hat{s}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}},$$

o escrito de otra forma,

$$se(\hat{\beta}_0) = \sqrt{\frac{\hat{s}^2}{s_{xx}}}, \quad y \quad se(\hat{\beta}_1) = \sqrt{\hat{s}^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{s_{xx}} \right]},$$

donde $s_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$.

Del Teorema de Gauss-Markov y las estimaciones anteriores se pueden establecer intervalos de confianza para los parámetros β_0 , β_1 y σ^2 .

Intervalo de confianza para β_0

$$\hat{\beta}_0 - t_{1-\alpha/2} \cdot se(\hat{\beta}_0) \leq \beta_0 \leq \hat{\beta}_0 + t_{1-\alpha/2} \cdot se(\hat{\beta}_0).$$

Intervalo de confianza para β_1

$$\hat{\beta}_1 - t_{1-\alpha/2} \cdot se(\hat{\beta}_1) \leq \beta_1 \leq \hat{\beta}_1 + t_{1-\alpha/2} \cdot se(\hat{\beta}_1),$$

Observación: Los cuantiles involucrados en los dos intervalos de confianza anteriores corresponden a los de una distribución t -Student con $n - 2$ g.l.

Intervalo de confianza para σ^2

$$(n - 2) \frac{\hat{s}^2}{\chi_{1-\alpha/2}^2} \leq \sigma^2 \leq (n - 2) \frac{\hat{s}^2}{\chi_{\alpha/2}^2},$$

donde los cuantiles involucrados corresponden a los de una distribución Chi-cuadrado con $n - 2$ g.l.

Ejemplo: Nuevamente consideremos el ejemplo de edad vs grasas. Encontremos intervalos de confianza al 95 % para β_0 y β_1 . Al usar el comando `summary`, obtenemos las estimaciones de los coeficientes y la estimación de los errores estandar de los estimadores. Estos son:

$$\begin{aligned}\hat{\beta}_0 &= 102.57; & se(\hat{\beta}_0) &= 29.63, \\ \hat{\beta}_1 &= 5.32; & se(\hat{\beta}_1) &= 0.72.\end{aligned}$$

Además, $t_{1-\alpha/2} = 2.07$. Luego, los intervalos son:

$$102.57 - 2.07 \cdot 29.63 \leq \beta_0 \leq 102.57 + 2.07 \cdot 29.63,$$

y

$$5.32 - 2.07 \cdot 0.72 \leq \beta_1 \leq 5.32 + 2.07 \cdot 0.72,$$

es decir,

$$41.24 \leq \beta_0 \leq 163.90; \quad 3.83 \leq \beta_1 \leq 6.81.$$

Ejemplo: Encontramos un intervalo de confianza al 95 % para σ^2 para los datos de edad vs. grasas.

Nuevamente usando el comando `summary` obtenemos que $\hat{s} = 43.46$.

Además, tenemos $\chi_{\alpha/2}^2 = 11.69$ y $\chi_{1-\alpha/2}^2 = 38.08$.

Luego, el intervalo es

$$(25 - 2) \frac{43.46^2}{38.08} \leq \sigma^2 \leq (25 - 2) \frac{43.46^2}{11.69},$$

es decir,

$$1140.80 \leq \sigma^2 \leq 3716.14.$$

Observación: Con los supuestos del modelo de regresión lineal también pueden formularse intervalos de confianza para la respuesta media $E[Y | X = x_0]$ y para una observación futura y_0 para el valor x_0 .

Intervalo de confianza para $E[Y | X = x_0]$

$$\begin{aligned}
 (\hat{\beta}_0 + \hat{\beta}_1 x_0) - t_{1-\alpha/2} \hat{s} \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{s_{xx}}} \\
 \leq E[Y | X = x_0] \leq (\hat{\beta}_0 + \hat{\beta}_1 x_0) + t_{1-\alpha/2} \hat{s} \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{s_{xx}}} \quad (8)
 \end{aligned}$$

donde $t_{1-\alpha/2}$ es el cuantil $1 - \alpha/2$ de la distribución t-Student con $n - 2$ g.l.

Intervalo de confianza para y_0 para x_0

$$\begin{aligned} (\hat{\beta}_0 + \hat{\beta}_1 x_0) - t_{1-\alpha/2} \hat{s} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{s_{xx}}} \\ \leq y_0 \leq (\hat{\beta}_0 + \hat{\beta}_1 x_0) + t_{1-\alpha/2} \hat{s} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{s_{xx}}} \quad (9) \end{aligned}$$

Nuevamente los cuantiles corresponden a los de una t -Student con $n - 2$ grados de libertad.

Ejemplo: En el caso del ejemplo visto de edad vs grasas, el intervalo de confianza al 95 % para la respuesta media para $x_0 = 39$ es

$$292.10 \leq E[Y | X = 39] \leq 328.06.$$

Decimos entonces que hay un 95 % de confianza de que la media del nivel de grasas para individuos con 39 años de edad, esté entre 292.10 y 328.06 mg de triglicéridos/dl.

Para ese mismo conjunto de datos, un intervalo de predicción del 95 % para y_0 para $x_0 = 39$ es

$$218.40 \leq y_0 \leq 401.77,$$

es decir, con un 95 % de confianza un individuo con 39 años de edad tendrá un nivel de grasas entre 218.40 y 401.77 mg de triglicéridos/dl.

PRUEBAS DE HIPÓTESIS

Nuevamente usando los supuestos del modelo de regresión lineal, es posible establecer pruebas de hipótesis para los coeficientes β_0 y β_1 .

H_0	Valor del estadístico de prueba bajo H_0	H_1	Región crítica
$\beta_0 = \delta_0$	$t_0 = \frac{\hat{\beta}_0 - \delta_0}{se(\hat{\beta}_0)}$	$\beta_0 \neq \delta_0$	$(-\infty, -t_{1-\alpha/2}) \cup (t_{1-\alpha/2}, \infty)$
		$\beta_0 < \delta_0$	$(-\infty, -t_{1-\alpha})$
		$\beta_0 > \delta_0$	$(t_{1-\alpha}, \infty)$

H_0	Valor del estadístico de prueba bajo H_0	H_1	Región crítica
$\beta_1 = \delta_0$	$t_0 = \frac{\hat{\beta}_1 - \delta_0}{se(\hat{\beta}_1)}$	$\beta_1 \neq \delta_0$	$(-\infty, -t_{1-\alpha/2}) \cup (t_{1-\alpha/2}, \infty)$
		$\beta_1 < \delta_0$	$(-\infty, -t_{1-\alpha})$
		$\beta_1 > \delta_0$	$(t_{1-\alpha}, \infty)$

Los cuantiles de ambas tablas corresponden a los de una t-Student con $n - 2$ g.l.

Usualmente se examina si los coeficientes de regresión son *estadísticamente significantes*, lo cual equivale a la siguiente prueba de hipótesis

$$H_0 : \beta_i = 0,$$

$$H_1 : \beta_i \neq 0.$$

para cada coeficiente.

Ejemplo: En el caso de los datos de edad y grasas, usando el software R se obtiene que β_0 es estadísticamente significativo para niveles de significación mayores a 0.002, y β_1 lo es para niveles de significación mayores a $1.79 \cdot 10^{-07}$.

INTERPRETACIÓN DE LOS COEFICIENTES DE REGRESIÓN

Consideremos el modelo de regresión ajustado:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x.$$

Note que si x aumenta en una unidad, es decir, se transforma en $x + 1$, el nuevo valor de $\hat{y}$ es

$$\hat{y}_N = \hat{\beta}_0 + \hat{\beta}_1(x + 1) = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_1.$$

Si hacemos la diferencia entre el nuevo valor de $\hat{y}_N$ y $\hat{y}$, se obtiene $\hat{\beta}_1$.

Esto significa que cuando la variable predictora aumenta en una unidad, estimamos que la variable respuesta aumentaría en $\hat{\beta}_1$ unidades.

En cuanto a la interpretación de $\hat{\beta}_0$, debemos ser cuidadosos de que X pueda tomar el valor cero o cercanos a cero. Si esto es posible, podemos interpretar $\hat{\beta}_0$ diciendo que “cuando la variable predictora toma valores muy cercanos a cero, la variable respuesta toma un valor muy cercano a $\hat{\beta}_0$ ”.

Ejemplo: Consideremos el modelo de regresión ajustado de de edad vs grasas:

$$\hat{y} = 102.57 + 5.32x.$$

La forma de interpretar el coeficiente estimado $\hat{\beta}_1$ es: “cuando la edad aumenta en 1 año, podemos estimar que la cantidad de triglicéridos (grasa) aumenta en 5.32 mg/dl”.

COEFICIENTE DE DETERMINACIÓN

Se puede probar la identidad siguiente:

$$\underbrace{\sum_{i=1}^n (y_i - \bar{y})^2}_{\text{SCT}} = \underbrace{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}_{\text{SCR}} + \underbrace{\sum_{i=1}^n (y_i - \hat{y}_i)^2}_{\text{SCE}} \quad (10)$$

donde:

- SCT: suma total de cuadrados (variación total)
- SCR: suma de cuadrados de la regresión (variación explicada)
- SCE: suma de cuadrados de los errores (variación no explicada)

Note que el término SCT puede ser pensado como la cantidad de variabilidad inherente en la respuesta.

El término SCR puede ser visto como la cantidad de variabilidad en la respuesta que es explicada (o removida) debido a la regresión.

Por tanto, una parte de la variación total de la respuesta es explicada por el modelo y otra no.

Note que una medida de la proporción de la variación total de la respuesta con respecto a su media que es explicada por el modelo estimado, es

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = \frac{\text{SCR}}{\text{SCT}} = 1 - \frac{\text{SCE}}{\text{SCT}} \quad (11)$$

A la medida R^2 se le conoce como *coeficiente de determinación*.

Note que $0 \leq R^2 \leq 1$. Es mejor tener un valor de R^2 lo más cercano a 1 posible, ya que significaría que la variación de la variable respuesta puede explicarse por la presencia de x en la ecuación de regresión (o dicho de otra forma, puede explicarse por el modelo estimado).

Ejemplo: Para el ejemplo de edad vs. grasas, se puede notar que el coeficiente de determinación es $R^2 = 0.7012$. Esto significa que aprox. un 70 % de la variabilidad de la respuesta es explicada por el modelo ajustado (o bien, por la edad).

Ejemplo: Para el ejemplo del salario y los años desde graduación, se puede encontrar que $R^2 = 0.9667$. Es decir, un alto porcentaje de la variabilidad del salario es explicado por los años desde graduación.

Observación: Se puede probar que en el caso de regresión lineal simple R^2 es igual al coeficiente de correlación entre X e Y al cuadrado. Por tanto, un coeficiente de determinación cercano a 1 indicaría una recta de regresión estimada que ajusta muy bien la nube de puntos.

Ejemplo: En el conjunto de datos sobre el nivel de grasas, al usar la variable edad como regresora, obtenemos $R^2 = 0.70$, mientras que si consideramos X como el peso, obtenemos 0.070. Esto implica que un mejor ajuste se logra con el primer modelo.

EVALUACIÓN DE LOS SUPUESTOS

Se define el residuo e_i como $y_i - \hat{y}_i$. Éste viene a ser una estimación del error ϵ_i (revise la formulación del modelo de regresión lineal).

Note que si definimos el residuo estandarizado

$$e_{is} = e_i / s,$$

se cumple que su media es cero y su varianza es cercana a 1.

Evaluación Supuestos 1 y 2: Para evaluar cualquiera de estos supuestos, se puede realizar un gráfico de x_i vs e_i o e_{is} .

Para validar el Supuesto 1, se requiere que la nube de puntos esté distribuida en torno al eje X .

Para validar el Supuesto 2, se requiere que el ancho de la banda de la nube de puntos sea aproximadamente el mismo. Si hay presencia de una forma de embudo o similar, entonces éste supuesto de varianza constante no se validaría.




Figura: Para regresión de edad vs grasas.

Evaluación Supuesto 3: La evaluación de este supuesto cuando las observaciones fueron tomadas en el tiempo, se puede realizar mediante una gráfica de orden vs $e_{i,s}$.

Si no vemos patrones aparentes podemos validar el Supuesto 3.




Figura: Gráfica valida supuesto de independencia

Evaluación Supuesto 4: Una vez validados los Supuestos 1 y 2, se acostumbra evaluar este supuesto examinando si los residuos estandarizados e_{is} siguen o no una distribución normal estándar.

Si el gráfico QQ-plot (quantiles empíricos vs quantiles teóricos) nos diera mostrara la mayoría de los puntos dentro de las bandas, aceptaríamos que los errores siguen una distribución normal con media cero y varianza constante.

Nota: Existen otros métodos no-gráficos, como el test de Shapiro-Wilks que también permite evaluar normalidad de los errores.

Ejemplo: Al realizar este gráfico para el ejemplo de edad vs grasas, se puede notar que el supuesto de normalidad estaría validado.




Figura: Para regresión edad vs. grasas.

Observación: La importancia de validar los supuestos del modelo radica en que de otro modo el modelo no describiría bien los datos y las inferencias sobre sus parámetros no tendrían validez.

Por ejemplo, si no se verifica el Supuesto 1 (linealidad en los parámetros), la recta de regresión no ajustaría bien la tendencia de la nube de puntos.

Otro ejemplo, si no se cumple la normalidad de los errores, las expresiones de los intervalos de confianza para β_0 y β_1 no son válidas.