

Teoría de colas

O

Líneas de Espera

Contenido

- Conceptos básicos
- Modelo canal simple población infinita: $M | M | 1$
- Modelo multicanal población infinita : $M | M | k$
- Modelo canal simple población finita : $M | M | 1 | M$
- Modelo multicanal población finita : $M | M | k | M$
(capacidad ilimitada)
- Modelo canal simple población infinita: $M | M | 1$
(capacidad limitada)

Conceptos básicos

Teoría de colas o líneas de espera

Cuando se tiene un problema de congestión o atochamiento, estamos frente a un problema líneas de espera. La teoría de colas analiza la causa de la formación de la cola, que es la existencia de momentos en los que hay una mayor demanda de servicio que la capacidad de servicio.



Tanto las llegadas como los servicios son variable aleatorias y con ellas podemos caracterizar el sistema permitiendo la toma de decisiones.

En particular nos interesará: probabilidad de que el sistema este vacío, probabilidad de que hayan n unidades en el sistema, número promedio de unidades en cola o en el sistema, tiempo promedio en cola o en el sistema, etc.




Elementos a considerar:

- Llamaremos **clientes**, trabajos o tareas a los que demandan servicio.



- **Canal de servicio** (empleados o servidores): a los que entregan algún servicio.



- Una **cola** son clientes que esperan recibir un determinado servicio. Este servicio lo proporciona uno o varios dependientes (canal simple, multicanal).

- **Nº clientes (M)**: es el nº de clientes potenciales del sistema. (finito o infinito).

Clasificación de sistemas de colas

- Un sistema de colas viene dado por varias características:
 - 1º **Modelo de llegada de clientes**, El índice de llegadas será el número medio de llegadas por unidad de tiempo. Alternativamente podemos usar el tiempo entre llegadas, que es el tiempo medio entre llegadas sucesivas
 - Tiempo promedio entre llegadas ($1/\lambda$) unidad de tiempo
 - Tasa de llegada (λ) unidad/unidad de tiempo.

Ejemplo: En cada uno de los casos siguientes, determine la frecuencia o tasa promedio de llegadas por hora.

- (a) Una llegada cada 10 minutos.
- (b) Dos llegadas cada 6 minutos.
- (c) La cantidad de llegadas en un período de 30 minutos es de 5.
- (d) El intervalo promedio entre las llegadas sucesivas es 0.5 horas.

Clasificación de sistemas de colas

- **2º Modelo de servicio**, Puede venir dado por el tiempo de servicio o por el número de clientes atendidos por unidad de tiempo, Tendremos una variable aleatoria o bien un servicio determinista, Aquí supondremos que el modelo de servicio es independiente del de llegada.
 - Tiempo promedio entre servicios ($1/\mu$) unidad de tiempo
 - Tasa de servicio (μ) unidad/unidad de tiempo.

Ejemplo: En cada uno de los casos siguientes, determine la frecuencia o tasa promedio de servicio por hora.


- (a) Se termina un servicio cada 12 minutos.
- (b) Hay dos salidas cada 15 minutos.
- (c) Número clientes atendidos en un período de 30 minutos es de 10.
- (d) El tiempo promedio de servicio es de 0.3 horas.

Clasificación de sistemas de colas

- **3º Disciplina de la cola**, Establece el orden en que se atiende a los clientes:
 - Por orden de llegada (FIFO)
 - Por orden inverso al de llegada (LIFO)
 - Selección aleatoria (RANDOM)
 - Según prioridades (PRIORITY, PR), Dos subtipos:
 - Con interrupción, Si llega un cliente de más prioridad, el trabajo que se estaba sirviendo se interrumpe para atenderlo
 - Sin interrupción, No se pueden interrumpir los trabajos
 - Dentro de cada clase de prioridad se podrán aplicar disciplinas LIFO, FIFO o RANDOM.

Clasificación de sistemas de colas

- **4º Capacidad del sistema**, Es el número máximo de clientes que puede haber en el sistema (finito o infinito). Finito es cuando llega un cliente y el sistema está lleno, se marcha.
- **5º Número de canales de servicio.**
Puede haber una cola para cada servidor o bien una sola cola global
- **6º Número de estados de servicio**, Puede haber varias partes en las que se subdivide el trabajo (estados), cada una con su cola y su servidor, que deben ser completadas sucesivamente. Por ejemplo, tres estados:



Notación de Kendall

- La notación de Kendall nos permite escribir resumidamente todas las características que hemos estudiado, Un sistema de colas se notará como: $A | B | X | Y | Z | V$, donde:
 - A es el modelo de llegadas, Valores posibles:
 - M=tiempos entre llegadas exponenciales
 - D=tiempos entre llegadas deterministas
 - G= tiempos entre llegadas generales (cualquier distribución)
 - B es el modelo de servicio, Puede tomar los mismos valores que A

Notación de Kendall

- X es el número de servidores.
 - Y es la capacidad del sistema (número máximo de clientes en el sistema), Se puede omitir si es infinita
 - Z es la disciplina, Se puede omitir si es FIFO
 - V es el número de estados de servicio, Se puede omitir si es 1
- Por ejemplo, $M | M | 1 | \infty | \text{FIFO} | 1$ se escribe abreviadamente $M | M | 1$

Medidas de rendimiento

- Una vez descrito el sistema, nuestro objetivo es evaluar su rendimiento, Para ello tenemos varias medidas de rendimiento:
 - Número medio de clientes en el sistema, notado L
 - Tiempo medio de espera de los clientes, W
 - Número medio de clientes en la cola, L_q
 - Tiempo medio de espera en cola de los clientes, W_q

$M | M | 1$

Modelo canal simple población
infinita.

Descripción del modelo

- Hay una sola cola, cuya capacidad es infinita, y un solo servidor, La disciplina será FIFO
- Las llegadas se producen según un proceso de Poisson de razón λ , donde λ es el número medio de llegadas por unidad de tiempo y $1/\lambda$ es el tiempo medio entre llegadas, Los tiempos entre llegadas se distribuirán exponencialmente, $\text{Exp}(1/\lambda)$
- Los tiempos entre servicios también se distribuirán exponencialmente, $\text{Exp}(1/\mu)$, de tal manera que μ es el número medio de clientes que el servidor es capaz de atender por unidad de tiempo y $1/\mu$ es el tiempo medio de servicio

Condición de no saturación

- Se demuestra que si $\lambda \geq \mu$, el sistema se satura, es decir, el número de clientes en la cola crece indefinidamente con el tiempo, Por consiguiente, la condición de no saturación será:

$$\rho < 1, \text{ donde } \rho = \frac{\lambda}{\mu}$$

- Nosotros sólo estudiaremos las colas que no se saturan, Cuando una cola no se satura, también se dice que alcanza el estado estacionario,

Probabilidades

- El parámetro ρ se llama carga, flujo o intensidad de tráfico del sistema, puesto que mide la relación entre la cantidad de trabajos que llegan y la capacidad de procesarlos
- Suponiendo que el sistema no se satura, se deduce la siguiente fórmula para las probabilidades p_n de que haya n clientes en el sistema, donde $n \in \mathbf{N}$:

$$p_0 = (1-\rho) \qquad p_n = \rho^n (1-\rho)$$

Medidas de rendimiento

- El número medio de clientes en el sistema, L , se calcula así:

$$L = \sum_{j=0}^{\infty} j p_j = \sum_{j=0}^{\infty} j \rho^j (1-\rho) = (1-\rho) \sum_{j=0}^{\infty} j \rho^j = (1-\rho) * S$$

Sumamos la serie aritmético-geométrica:

$$\begin{array}{r} S = \rho + 2\rho^2 + 3\rho^3 + 4\rho^4 + \dots \\ - \rho S = \quad -\rho^2 - 2\rho^3 - 3\rho^4 + \dots \\ \hline (1-\rho)S = \rho + \rho^2 + \rho^3 + \rho^4 + \dots = \frac{\rho}{1-\rho} \\ \Rightarrow L = (1-\rho) \frac{\rho}{(1-\rho)^2} = \frac{\rho}{1-\rho} \end{array}$$

Medidas de rendimiento

- La utilización del servidor, notada U , es la fracción de tiempo (en tanto por uno) que el dependiente permanece ocupado, Para hallarla, nos valemos de que cuando no hay saturación, el número medio de clientes que entran en el sistema debe ser igual al número medio de clientes que salen de él:

$$\lambda = U\mu \Rightarrow U = \frac{\lambda}{\mu} = \rho$$

- Como para deducir la anterior fórmula no hemos usado ninguna característica especial del modelo de entrada ni del de salida, dicha fórmula es válida para colas $G | G | 1$

Medidas de rendimiento

- El tiempo medio de respuesta W es el tiempo medio que un trabajo permanece en el sistema, Si suponemos que un trabajo, al llegar al sistema, se encuentra con que hay por delante de él otros j trabajos, el tiempo medio que tardará en salir del sistema será $j+1$ veces el tiempo medio de servicio, Por lo tanto:

$$W = \sum_{j=0}^{\infty} (j+1) \frac{1}{\mu} p_j = \sum_{j=0}^{\infty} j \frac{1}{\mu} p_j + \sum_{j=0}^{\infty} \frac{1}{\mu} p_j = \frac{L}{\mu} + \frac{1}{\mu}$$

Tiempo que se pasa
en el sistema si
hay j por delante
al llegar

Probabilidad de que
haya j por delante
al llegar

Medidas de rendimiento

- Podemos simplificar algo más:

$$W = \frac{L}{\mu} + \frac{1}{\mu} = \frac{1}{\mu - \lambda}$$

- El tiempo medio de espera en la cola W_q se hallará restando a W el tiempo que tarda en ser servido el trabajo (esto es válido para cualquier tipo de cola):

$$W_q = W - \frac{1}{\mu}$$

- En el caso particular de una cola $M | M | 1$, obtenemos:

$$W_q = \frac{\rho}{\mu - \lambda}$$

Ejemplo 1.-

Unos mecánicos llegan a una media de 10 por hora a recoger piezas de repuesto. Estas piezas se las da otro empleado cuyo sueldo es de 500 \$/hora y que tarda como media 5 min en servir. Cada hora que un mecánico tiene que esperar se le debe pagar igual y su valor es de 1.000 \$/hora. Queremos saber si vale la pena contratar a un ayudante, pagado a 400 \$/hora, de forma que el tiempo medio de servicio se reduzca a 4 min.

Nota: Al resolver un problema de colas, tener siempre muy presente la coherencia de unidades.

Ejemplo 1 (cont)

- Tenemos dos opciones:
 - Sin ayudante: $1/\mu_1 = 5 \text{ min} = 1/12 \text{ h} \Rightarrow \mu_1 = 12 \text{ u/h}$
 - Con ayudante: $1/\mu_2 = 4 \text{ min} = 1/15 \text{ h} \Rightarrow \mu_2 = 15 \text{ u/h}$
- En ambos casos, $\lambda = 10 \text{ clientes/h}$
- Opción 1 (sin ayudante):

$$\rho = \frac{\lambda}{\mu} \Rightarrow \rho_1 = \frac{10}{12}; \quad L_1 = \frac{\rho_1}{1 - \rho_1} = \frac{\frac{10}{12}}{1 - \frac{10}{12}} = 5 \quad \text{mecánicos}$$

Por tanto, Costo/hora = $5 \cdot (1000\$/h) + 500 = 5500\$/h$

Ejemplo 1 (cont)

- Opción 2 (con ayudante):

$$\rho_2 = \frac{10}{15}; \quad L_2 = \frac{\rho_2}{1 - \rho_2} = \frac{\frac{10}{15}}{1 - \frac{10}{15}} = 2 \quad \text{mecánicos}$$

Por tanto, Costo/hora = $2 \cdot (1000\$/h) + 500 + 400 = 2900\$/h$, con lo cual la más ventajosa es la opción 2,

Más medidas de rendimiento

- El número medio de trabajos en la cola L_q , se calcula restándole a L el número medio de trabajos que están siendo servidos:

$$L - L_q = (1 - p_0) = \rho \text{ ya que } L_q = \sum_{j=1}^{\infty} j p_{j+1} \Rightarrow L_q = L - \rho = \frac{\rho^2}{(1-\rho)}$$

- Probabilidad de que un cliente que llega pase más de t unidades de tiempo en el sistema:

$$P\{W > t\} = e^{-t/W}$$

- Probabilidad de que un cliente que llega pase más de t unidades de tiempo en la cola:

$$P\{W_q > t\} = \rho e^{-t/W}$$

Ejemplos 2.-

Un canal de comunicación se usa para enviar datos desde K computadores fuentes a uno central, Cada fuente envía paquetes de datos según un proceso de Poisson de razón 2 paquetes/seg, Además cada fuente envía independientemente de las otras. Todos los paquetes son idénticos, esperan en una cola común y después se transmiten de uno en uno. Los tiempos de transmisión se distribuyen exponencialmente, con media 25 mseg. Determinar el número máximo de fuentes que se pueden conectar al canal de tal manera que:

- 1.- El canal no se sature
- 2.- En media los paquetes no pasen en el sistema más de 100mseg.
- 3.- En el estado estacionario se garantice que al menos el 95% de los paquetes tenga un tiempo de respuesta que no exceda de 100 mseg

Ejemplos 2 (cont)

- 1º El canal no sesature
 - Si tenemos k fuentes, llegarán a la cola $2k$ paquetes/seg, Por otro lado, $1/\mu = 0,025$ seg $\Rightarrow \mu = 40$ paquetes/seg
 - El canal no se satura cuando $\rho < 1$:

$$\rho = \frac{\lambda}{\mu} = \frac{2k}{40} = \frac{k}{20} < 1 \Rightarrow k < 20 \text{ fuentes}$$

Ejemplos 2 (cont)

- 2º En media los paquetes no pasen en el sistema más de 100 mseg
 - Tal como ocurría en el caso anterior, llegarán a la cola $2k$ paquetes/seg, y tendremos $\mu = 40$ paquetes/seg
 - Nos exigen $W \leq 0,1$ seg:

$$W = \frac{1}{\mu - \lambda} = \frac{1}{40 - 2k} \leq 0,1 \Rightarrow k \leq 15 \text{ fuentes}$$

Ejemplos 2 (cont)


- 3º En el estado estacionario se garantice que al menos el 95% de los paquetes tenga un tiempo de respuesta que no exceda de 100 mseg
 - Tal como ocurría en el caso anterior, llegarán a la cola $2k$ paquetes/seg, y tendremos $\mu = 40$ paquetes/seg
 - Nos exigen que la probabilidad de que un paquete pase más de 100 mseg en el sistema sea inferior al 5%, es decir, $W(100 \text{ mseg}) \leq 0,05$:

$$P\{W(t > 0,1)\} \leq 0,05 \Rightarrow e^{-0,1(40-2k)} \leq 0,05 \Rightarrow 0,2k - 4 \leq \ln 0,05 \Rightarrow$$

$$k \leq \frac{4 + \ln 0,05}{0,2} \Rightarrow k \leq 5,021 \Rightarrow k \leq 5 \text{ fuentes (ya que } k \in \mathbf{N})$$

Ejemplo 3

Supongamos que una cola $M|M|1$ con parámetros λ y μ se sustituye por n colas $M|M|1$ independientes de parámetros λ/n y μ/n . Es decir, dividimos la carga de trabajo y la capacidad de proceso en n partes iguales. Evaluar el efecto del cambio usando como medidas de rendimiento el tiempo medio de respuesta y el número medio de trabajos en el sistema.



Ejemplo 3 (cont)

- Alternativa 1 (una sola cola), $\lambda_1=\lambda$, $\mu_1=\mu$:

$$L_1 = \frac{\rho_1}{1-\rho_1} = \frac{\lambda}{\mu-\lambda}$$
$$W_1 = \frac{1}{\mu_1-\lambda_1} = \frac{1}{\mu-\lambda}$$

- Alternativa 2 (n colas independientes), $\lambda_2=\lambda/n$, $\mu_2=\mu/n$:

$$L_2 = \sum_{i=1}^n \frac{\rho_2}{1-\rho_2} = n \frac{\rho_2}{1-\rho_2} = n \frac{\frac{\lambda/n}{\mu/n}}{1-\frac{\lambda/n}{\mu/n}} = n \frac{\lambda/\mu}{1-\lambda/\mu} = n \frac{\lambda}{\mu-\lambda} = nL_1$$

Ejemplo 3 (cont)

$$W_2 = \frac{1}{\mu_2 - \lambda_2} = \frac{1}{\mu/n - \lambda/n} = n \frac{1}{\mu - \lambda} = nW_1$$

- Como la alternativa 1 tiene menores valores para ambas medidas de rendimiento, concluimos que la dicha alternativa es mejor.
- Esto nos indica que lo mejor es no dividir la capacidad de procesamiento, es decir, tener un único servidor que atienda a todos los clientes.

Teorema de Little

- Sea un sistema de colas con cualquier distribución de llegadas y servicios y cualquier estructura. Sean L el número de trabajos presentes en el sistema en el estado estacionario, W es tiempo medio de respuesta en el estado estacionario y λ la razón de llegadas al sistema. Entonces:

$$L = \lambda W$$

Así, también se establece que:

$$L_q = \lambda W_q$$

FORMULAS

Utilización
del servidor $\rho = \frac{\lambda}{\mu}$

Número medio de
clientes en el sistema: $L = \frac{\rho}{1-\rho}$ $L = \lambda W$

Número medio de
clientes en cola: $L_q = \frac{\rho^2}{1-\rho}$ $L_q = \lambda W_q$

Tiempo medio que un
trabajo permanece en
el sistema o de
respuesta $W = \frac{L}{\mu} + \frac{1}{\mu} = \frac{1}{\mu - \lambda}$

Tiempo medio que un
trabajo permanece en
espera o en cola $W_q = W - \frac{1}{\mu}$ $W_q = \frac{\rho}{\mu - \lambda}$, para M/M/1

- Probabilidad que haya n clientes en el sistema:
 $P_0 = (1 - \rho)$ $P_n = \rho^n (1 - \rho)$
- Probabilidad de que un cliente que llega pase más de t unidades de tiempo en el sistema:

$$P\{W > t\} = e^{-t/W}$$

- Probabilidad de que un cliente que llega pase más de t unidades de tiempo en la cola:

$$P\{W_q > t\} = \rho e^{-t/W}$$

Ejemplo 4:

Una grúa desplaza cajas, el tiempo de registro entre llamadas tiene una media de 30 minutos. El tiempo de carga o descarga es en promedio 10 minutos. Si el tiempo de caja fuera de lugar es de \$850 la hora. Determine:

- i) Cuánto es el tiempo perdido por día?
- ii) Cuál es el costo perdido por día?
- iii) Cuál es la probabilidad que la espera en cola sea mayor a 20 minutos?
- iv) Cuál es la probabilidad que hayan más de dos cajas en el sistema?
- v) Cuál es la probabilidad que una unidad que llegue no tenga que esperar?

$M | M | k \quad (M | M | s)$

Modelo multicanal población infinita

Descripción del modelo

- Hay una sola cola, cuya capacidad es infinita, y k servidores, La disciplina será FIFO
- Las llegadas se producen según un proceso de Poisson de razón λ , donde λ es el número medio de llegadas por unidad de tiempo y $1/\lambda$ es el tiempo medio entre llegadas, Los tiempos entre llegadas se distribuirán exponencialmente, $\text{Exp}(1/\lambda)$
- Los tiempos de servicio también se distribuirán exponencialmente, $\text{Exp}(1/\mu)$, de tal manera que μ es el número medio de clientes que cada servidor es capaz de atender por unidad de tiempo y $1/\mu$ es el tiempo medio de servicio

Condición de no saturación

- Se demuestra que si $\lambda \geq k\mu$, el sistema se satura, es decir, el número de clientes en la cola crece indefinidamente con el tiempo, Por consiguiente, la condición de no saturación será:

$$\rho_k < 1, \text{ donde } \rho_k = \frac{\lambda}{k\mu}$$

- Nosotros sólo estudiaremos las colas que no se saturan, Cuando una cola no se satura, también se dice que alcanza el estado estacionario.

Probabilidades

- Suponiendo que el sistema no se satura, se deducen las siguientes fórmulas para las probabilidades p_n de que haya n clientes en el sistema, donde $n \in \mathbb{N}$:

$$p_0 = \left(\frac{\left(\frac{\lambda}{\mu}\right)^k k\mu}{k!(k\mu - \lambda)} + \sum_{n=0}^{k-1} \frac{\left(\frac{\lambda}{\mu}\right)^n}{n!} \right)^{-1}$$
$$p_n = \begin{cases} \frac{\left(\frac{\lambda}{\mu}\right)^n}{n!} & p_0, \text{ si } n = 0, 1, \dots, k \\ \frac{\left(\frac{\lambda}{\mu}\right)^n}{k!k^{n-k}} & p_0, \text{ en otro caso} \end{cases}$$

Medidas de rendimiento

- Número medio de clientes en cola:

$$L_q = \frac{\lambda \mu \left(\frac{\lambda}{\mu} \right)^k p_0}{(k-1)!(k\mu - \lambda)^2}$$

- Usamos razonamientos ya vistos para obtener:

$$L_q = \lambda W_q \quad \Rightarrow \quad W_q = \frac{L_q}{\lambda}$$

$$W = W_q + \frac{1}{\mu}$$

$$L = \lambda W$$

Otras medidas de rendimiento

- Número medio de servidores ocupados, L_{ss} , En el estado estacionario, la razón de las salidas será igual a la razón de las llegadas:

$$L_{ss} = \frac{\lambda}{\mu}$$


- Probabilidad de que un trabajo tenga que esperar para recibir su servicio (fórmula de retraso de Erlang):

$$P_K = \frac{k\mu \left(\lambda/\mu\right)^k p_0}{k! (k\mu - \lambda)}$$


Ejemplo 1

- Usando el número medio de unidades en el sistema (L) como medida de rendimiento, comparar estas dos alternativas:

Alternativa 1:



Alternativa 2:



Ejemplo 1 (cont)

- Alternativa 1:

$$L_1 = \frac{\rho}{1-\rho}$$

- Alternativa 2:

$$\rho_2 = \frac{\lambda}{2\frac{\mu}{2}} = \frac{\lambda}{\mu} = \rho$$

$$p_0 = \left(\frac{\left(\frac{\lambda}{\mu}\right)^k k\mu}{k!(k\mu - \lambda)} + \sum_{n=0}^{k-1} \frac{\left(\frac{\lambda}{\mu}\right)^n}{n!} \right)^{-1}$$

$$p_{02} = \left(\frac{2^2 \rho^2}{2!(1-\rho)} + \sum_{n=0}^{2-1} \frac{(2\rho)^n}{n!} \right)^{-1}$$

$$p_0 = \left(\left(\frac{\lambda}{\mu} \right)^k k\mu + \sum_{n=0}^{k-1} \frac{\left(\frac{\lambda}{\mu} \right)^n}{n!} \right)^{-1}$$

$$p_{02} = \left(\frac{4\rho^2}{2(1-\rho)} + 1 + 2\rho \right)^{-1} = \left(\frac{4\rho^2 + 2 - 2\rho + 4\rho - 4\rho^2}{2(1-\rho)} \right)^{-1}$$

$$p_{02} = \left(\frac{2 + 2\rho}{2(1-\rho)} \right)^{-1} = \frac{1-\rho}{1+\rho}$$

$$L_2 = \lambda W_2 = \lambda \left(W_{q2} + \frac{1}{\frac{\mu}{2}} \right) = \lambda W_{q2} + \frac{2\lambda}{\mu} = \lambda W_{q2} + 2\rho$$

$$L_2 = L_{q2} + 2\rho = \frac{4\rho^3 p_{02}}{2(1-\rho)^2} + 2\rho = \frac{2\rho^3(1-\rho)}{(1-\rho)^2(1+\rho)} + 2\rho$$

Ejemplo 1 (cont)

$$L_2 = \frac{2\rho^3}{(1-\rho)(1+\rho)} + 2\rho = \frac{2\rho^3 + 2\rho - 2\rho^3}{(1-\rho)(1+\rho)} = \frac{2\rho}{(1-\rho)(1+\rho)}$$

- Para que la alternativa 1 sea mejor, ha de cumplirse que $L_1 < L_2$:

$$\frac{\rho}{1-\rho} < \frac{2\rho}{(1+\rho)(1-\rho)} \Rightarrow \left\{ \frac{\rho}{1-\rho} > 0 \right\} \Rightarrow 1 < \frac{2}{1+\rho}$$


$$\Rightarrow 1 + \rho < 2 \Rightarrow \rho < 1$$

- Como $\rho < 1$ siempre se cumple, tendremos que la alternativa 1 siempre es mejor, Es decir, no conviene dividir la capacidad de procesamiento en dos servidores.


Ejemplo 2

- Usando el número medio de clientes en el sistema (L) como medida de rendimiento, comparar estas dos alternativas:

Alternativa 1:



Alternativa 2:



Ejemplo 2 (cont)

- Alternativa 1 (nótese que hay 2 colas):

$$L_1 = 2 \frac{\rho_1}{1 - \rho_1} = \frac{2\rho}{1 - \rho}, \quad \text{donde} \quad \rho = \frac{\lambda}{\mu}$$

- Alternativa 2 (es la alternativa 2 del ejemplo anterior):

$$\rho_2 = \frac{\lambda}{2 \frac{\mu}{2}} = \frac{\lambda}{\mu} = \rho$$

$$L_2 = \frac{2\rho}{(1 - \rho)(1 + \rho)}$$

Ejemplo 2 (cont)

- Para que la alternativa 2 sea mejor, ha de cumplirse que $L_1 > L_2$:

$$\frac{2\rho}{1-\rho} > \frac{2\rho}{(1+\rho)(1-\rho)} \Rightarrow \left\{ \frac{2\rho}{1-\rho} > 0 \right\} \Rightarrow 1 > \frac{1}{1+\rho}$$

$$\Rightarrow 1 + \rho > 1 \Rightarrow \rho > 0$$

- Como $\rho > 0$ siempre se cumple, tendremos que la alternativa 2 siempre es mejor, Es decir, no conviene poner dos colas, sino tener una única cola global

Ejemplo 3

- En una copiadora se dispone de 3 máquinas fotocopadoras a disposición del público, Cada máquina es capaz de servir, por término medio, 8 trabajos cada hora, A la copiadora llegan como promedio 5 clientes a la hora,

Parámetros del sistema: $\lambda = 5$ clientes/h, $\mu = 8$ clientes/h, $k = 3$ servidores, El sistema no se satura porque $\rho_k < 1$,

$$\rho_k = \frac{\lambda}{k\mu} = \frac{5}{3 \cdot 8} = \frac{5}{24}$$

Ejemplo 3 (cont)

- ¿Cuál es la probabilidad de que las tres máquinas estén libres a la vez?

$$P_0 = \left(\frac{k\mu \left(\frac{\lambda}{\mu} \right)^n}{k!(k\mu - \lambda)} + \sum_{n=0}^{k-1} \frac{\left(\frac{\lambda}{\mu} \right)^k}{n!} \right)^{-1} = \left(\frac{8 * 3 \left(\frac{5}{8} \right)^3}{3!(3 * 8 - 5)} + \sum_{n=0}^2 \frac{\left(\frac{5}{8} \right)^n}{n!} \right)^{-1} =$$
$$\left(\frac{24 * 0,625^3}{3!(19)} + \frac{(0,625)^0}{0!} + \frac{(0,625)^1}{1!} + \frac{(0,625)^2}{2!} \right)^{-1} = \frac{1}{1,87} \approx 0,5342706$$

$$L_q = \frac{\mu \lambda \left(\frac{\lambda}{\mu} \right)^k P_0}{(k-1)!(k\mu - \lambda)^2} = \frac{5 * 8 * 0,625^3 * 0,5343}{2!(24 - 5)^2} = \frac{5,218}{722} \approx 0,00722643 \text{ clientes}$$

Ejemplo 3 (cont)

- ¿Cuál es el tiempo medio de espera en la cola?

$$W_q = \frac{L_q}{\lambda} = \frac{302}{5 \cdot 41791} = \frac{52}{35979} \approx 0,00144529 \text{ h}$$

- ¿Cuál es el tiempo medio de espera en el sistema?

$$W = W_q + \frac{1}{\mu} = \frac{52}{35979} + \frac{1}{8} = \frac{514}{4065} \approx 0,126445 \text{ h}$$

- ¿Cuál es el número medio de clientes en el sistema?

$$L = \lambda W = 5 \cdot \frac{514}{4065} = \frac{514}{813} \approx 0.632226 \text{ clientes}$$

Ejemplo 3 (cont)

- ¿Cuál es el número medio de fotocopadoras desocupadas?

$$p_0 = 0,534 \quad p_1 = 0,534 * \frac{5}{8} = 0,33 \quad p_2 = \frac{0,534}{2} * \left(\frac{5}{8}\right)^2 = 0,104$$

$$S = 3 * p_0 + 2p_1 + 1p_2 = 2,36$$

3 maq. por la prob. que no hayan clientes
+ 2 maq. por la prob de 1 cliente en el sistema + 1 maq. * prob(2)

- ¿Cuál es el número medio de fotocopadoras ocupadas?

$$P_3 = \frac{3 * 8 \left(\frac{5}{8}\right)^3 0,543}{3! (3 * 8 - 5)} = 0,027$$

-> Prob que un trabajo tenga que esperar.

$$S = 1p_1 + 2p_2 + 3p_K = 0,622 \quad o \quad L_{ss} = L - Lq = 0,62$$

1 maq. por la prob. de 1 cliente en el sistema
+ 2 maq. * prob(2) + 3 maq * prob(3)

Num medio de servidores ocupados

Ejemplo 3 (cont)

- ¿Cuál es la probabilidad de que hayan dos fotocopias en cola?

$$p_0 = 0,534 \quad p_5 = \frac{0,534 * \left[\frac{5}{8}\right]^5}{3! 3^{5-3}} = 0,00185$$

- ¿Cuál es la probabilidad que hayan más de tres unidades en el sistema?

$$P_3 = \frac{\left(\frac{5}{8}\right)^3 0,543}{3! * 3^0} = 0,022$$

$$P = 1 - p_0 - p_1 - p_2 - p_3 = 1 - 0,534 - 0,333 - 0,104 - 0,022 = 0,007$$

$$\text{o bien } P = P_k - p_3 = 0,027 - 0,022 = 0,006$$

Ejemplo 4.

Seis empleados atienden seis cajas para clientes que llegan a una tasa promedio de 12 clientes/hora. Cada empleado puede atender a una tasa media de 15 clientes/hora.

Se tiene las siguientes políticas de atención:

- i) Empleados trabajan en un equipo de 6 cajas, una sola cola.
- ii) Trabajan en equipos de 2 cajas y una cola en común.
- iii) Trabajan en equipo de 3 cajas y cola en común.
- iv) Trabajan cada uno individualmente.

- 1.- Determine la opción de menor tiempo en cola.
- 2.- determine la probabilidad que una unidad que llegue no tenga que esperar.
- 3.- Encuentre la probabilidad de que hayan 3 o más unidades en cola en cada opción.

$M | M | 1 | M \quad (M | M | 1 | k)$

Modelo canal simple población
finita

Descripción del modelo

- Hay una sola cola, cuya capacidad es finita ($M < 20$), y un servidor, La disciplina será FIFO
- Las llegadas se producen según un proceso de Poisson de razón λ , donde λ es el número medio de llegadas por unidad de tiempo y $1/\lambda$ es el tiempo medio entre llegadas, Los tiempos entre llegadas se distribuirán exponencialmente, $\text{Exp}(1/\lambda)$
- Los tiempos de servicio también se distribuirán exponencialmente, $\text{Exp}(1/\mu)$, de tal manera que μ es el número medio de clientes que cada servidor es capaz de atender por unidad de tiempo y $1/\mu$ es el tiempo medio de servicio

Condición de no saturación

- Se demuestra que si $\lambda \geq \mu$, el sistema se satura, es decir, el número de clientes en la cola crece indefinidamente con el tiempo, Por consiguiente, la condición de no saturación será:

$$\rho < 1, \text{ donde } \rho = \frac{\lambda}{\mu}$$

- Nosotros sólo estudiaremos las colas que no se saturan, Cuando una cola no se satura, también se dice que alcanza el estado estacionario,

Probabilidades

- Suponiendo que el sistema no se satura, se deducen las siguientes fórmulas para las probabilidades p_n de que haya n clientes en el sistema, donde $n \in \mathbf{N}$:

$$p_0 = \left(\sum_{n=0}^M \frac{M! \left(\frac{\lambda}{\mu} \right)^n}{(M-n)!} \right)^{-1}$$

$$p_n = \left\{ \frac{M! \left(\frac{\lambda}{\mu} \right)^n}{(M-n)!} p_0 \right.$$

Medidas de rendimiento

- Número medio de clientes en cola:

$$L_q = M - \frac{(\lambda + \mu)(1 - p_0)}{\lambda}$$

- Usamos razonamientos ya vistos para obtener:

$$W = W_q + \frac{1}{\mu}$$

$$L_q = \mu(1 - p_0)W_q$$

$$L = L_q + (1 - p_0)$$

Ejemplo 1

- Una empresa tiene 4 aviones jumbo, las fallas de las turbinas y el tiempo promedio entre dos fallas consecutivas es de un año. El tiempo promedio de revisión es de 45 días ($1/8$ año).

Se tienen los siguientes costos:

- Costo estar en pana: 2000 US/hora
- Sueldo tripulación: 400.000 US/mes
- Costo equipo reparación: 300.000 US/mes

Parámetros del sistema: $\lambda = 1$ turbina/año, $\mu = 8$ turbinas/año, $M = 4$ clientes potenciales, El sistema no se satura porque $\rho < 1$,

Ejemplo 1 (cont)

- ¿Cuál es la probabilidad que el sistema esté vacío?

$$p_0 = \left(\sum_{n=0}^M \frac{M! \left(\frac{\lambda}{\mu} \right)^n}{(M-n)!} \right)^{-1} = \left(1 + \frac{4!(1/8)}{3!} + \frac{4!(1/8)^2}{2!} + \frac{4!(1/8)^3}{1!} + \frac{4!(1/8)^4}{0!} \right)^{-1} = 1/1,74 = 0,574$$

- ¿Cuántos aviones están funcionando en promedio?

$$L_q = M - \frac{(\lambda + \mu) (1 - p_0)}{\lambda} = 4 - \frac{(1+8)(1-0,574)}{1} \approx 0,17 \text{ aviones}$$

$$L = 0,17 + (1 - 0,574) = 0,6 \text{ aviones}$$

$$M - L = 4 - 0,6 = 3,4 \text{ aviones funcionando}$$

Ejemplo 1 (cont)

- ¿Cuál es el tiempo promedio en el sistema?

$$W = L / \mu(1 - p_0) = 0,6 / 8(1 - 0,574) = 0,176 \text{ años}$$

- ¿Cuánto es el costo promedio mensual asociado?

$$Cto = (W - W_q) * cto \text{ reparación} + W * cto \text{ pana} + \text{suelo tripulación}$$

$$= 0,051 / 12 * 300.000 + 0,176 / 12 * 2000 * 14 * 30 + 400.000 = ? \text{ US/mes}$$

Supuestos: A la tripulación se le paga trabajo o no.

Costo de reparación está asociado con el tiempo de servicio

El avión trabaja 14 horas diarias y 30 días al mes.

$M \mid M \mid k \mid M \quad (M \mid M \mid s \mid k)$

Modelo multicanal
población finita,

Descripción del modelo

- Hay una sola cola, cuya capacidad es finita ($M < 20$), y k servidores, La disciplina será FIFO
- Las llegadas se producen según un proceso de Poisson de razón λ , donde λ es el número medio de llegadas por unidad de tiempo y $1/\lambda$ es el tiempo medio entre llegadas, Los tiempos entre llegadas se distribuirán exponencialmente, $\text{Exp}(1/\lambda)$
- Los tiempos de servicio también se distribuirán exponencialmente, $\text{Exp}(1/\mu)$, de tal manera que μ es el número medio de clientes que cada servidor es capaz de atender por unidad de tiempo y $1/\mu$ es el tiempo medio de servicio

Condición de no saturación

- Se demuestra que si $k\lambda \geq \mu$, el sistema se satura, es decir, el número de clientes en la cola crece indefinidamente con el tiempo, Por consiguiente, la condición de no saturación será:

$$\rho_k < 1, \quad \text{donde} \quad \rho_k = \frac{\lambda}{k\mu}$$

- Nosotros sólo estudiaremos las colas que no se saturan, Cuando una cola no se satura, también se dice que alcanza el estado estacionario,

Probabilidades

- Suponiendo que el sistema no se satura, se deducen las siguientes fórmulas para las probabilidades p_n de que haya n clientes en el sistema, donde $n \in M$:

$$p_0 = \left(\sum_{n=0}^{k-1} \frac{M! \left(\frac{\lambda}{\mu} \right)^n}{(M-n)n!} + \sum_{n=k}^M \frac{M! \left(\frac{\lambda}{\mu} \right)^n}{(M-n)k!k^{n-k}} \right)^{-1}$$
$$p_n = \begin{cases} \frac{M! \left(\frac{\lambda}{\mu} \right)^n}{(M-n)!n!} p_0, & \text{si } n \leq k \\ \frac{M! \left(\frac{\lambda}{\mu} \right)^n}{(M-n)!k!k^{n-k}} p_0, & \text{si } n \geq k \leq M \end{cases}$$

Medidas de rendimiento

- Número medio de clientes en cola:

$$L_q = \sum_{n=k}^M (n - k) p_n$$

$$L = \sum_{n=0}^M n p_n$$

- Usamos razonamientos ya vistos para obtener:

$$W = W_q + \frac{1}{\mu}$$

$$W_q = \frac{L_q}{\mu(L - L_q)}$$

$$W = \frac{L}{\mu(L - L_q)}$$

Ejemplo 1

- Una línea de buses interurbano tiene 2 grupos de técnicos especializados, los buses llegan en promedio a repararse 5 al mes. El tiempo promedio de servicio toma 30 horas. La línea tiene 8 buses.

Supuesto: los buses trabajan 30 días al mes y 10 horas diarias.

Parámetros del sistema: $\lambda = 5/30$ buses/día = $1/60$ buses/hora, $\mu = 1/30$ buses/hora, $M = 8$ clientes potenciales, $k=2$. El sistema no se satura porque $\rho < 1$, $\lambda / k\mu = 1/4$

Ejemplo 1 (con

- ¿Cuál es la probab

$$p_0 = \left(1 + \frac{8!(1/2)}{7!} + \frac{8!(1/2)^2}{6!*2!} + \frac{8!(1/2)^3}{5!*2!*2} \right)$$

$$(1 + 4 + 7 + 10,5 + 13,125 + 13,125 + 9,844 + 4,922 + 1,23)^{-1} = 64,746^{-1} \approx 0,0154$$

- ¿Cuántos buses están funcionando en promedio?

$$p_1 = 4 * 0,0154 = 0,0618$$

$$p_2 = 7 * 0,154 = 0,108$$

$$p_3 = 10,5 * 0,0154 = 0,162$$

$$p_4 = 13,125 * 0,0154 = 0,203$$

$$p_5 = 13,125 * 0,0154 = 0,203$$

$$p_6 = 9,844 * 0,0154 = 0,152$$

$$p_7 = 4,922 * 0,0154 = 0,076$$

$$p_8 = 1,23 * 0,0154 = 0,019$$

$$L = \sum_{n=0}^M n p_n = p_1 + 2p_2 + 3p_3 + 4p_4 + 5p_5 + 6p_6 + 7p_7 + 8p_8 = 4,206 \text{ buses}$$

$$M - L = 8 - 4,206 = 3,8 \text{ buses funcionando}$$

$$p_n = \begin{cases} \frac{M! \left(\frac{\lambda}{\mu} \right)^n}{(M-n)!n!} p_0, & \text{si } n \leq k \\ \frac{M! \left(\frac{\lambda}{\mu} \right)^n}{(M-n)!k!k^{n-k}} p_0, & \text{si } n \geq k \leq M \end{cases}$$

Ejemplo 1 (cont)

- ¿Cuál es el número promedio de estaciones de servicio utilizadas?

$$L_q = \sum_{n=k}^M (n-k) p_n = p_3 + 2p_4 + 3p_5 + 4p_6 + 5p_7 + 6p_8 = 2,278 \text{ buses}$$

$$L - L_q = 4,185 - 2,278 = 1,907 \text{ estaciones de ocupadas}$$

- ¿Cuál es el tiempo promedio que un bus está descompuesto?

$$W = \frac{L}{\mu(L - L_q)} = \frac{4,185 * 30}{1,907} = 65,84 \text{ horas} \approx 6,6 \text{ días}$$

$M | M | 1 | M \quad (M | M | 1 | k)$

**Modelo canal simple población
infinita, capacidad limitada**

Descripción del modelo

- Hay una sola cola, cuya disciplina será FIFO, La capacidad del sistema es limitada, de tal modo que sólo puede haber M clientes como máximo en el sistema, Por lo tanto, el número máximo de clientes en la cola es $M-1$, Si un cliente llega y el sistema está lleno, es rechazado y nunca más regresa
- Las llegadas se producen según un proceso de Poisson de razón λ , Los tiempos entre llegadas se distribuirán exponencialmente, $\text{Exp}(1/\lambda)$
- Los tiempos entre servicios también se distribuirán exponencialmente, $\text{Exp}(1/\mu)$, de tal manera que μ es el número medio de clientes que el servidor es capaz de atender por unidad de tiempo

Probabilidades

- El sistema nunca se satura, ya que la capacidad es limitada
- Se deduce la siguiente fórmula para las probabilidades p_n de que haya n clientes en el sistema, donde $n \in \{0, 1, 2, \dots, M\}$:

$$p_n = \begin{cases} \frac{\rho^n (1-\rho)}{1-\rho^{M+1}}, & \text{si } \rho \neq 1 \\ \frac{1}{M+1}, & \text{si } \rho = 1 \end{cases}$$

Probabilidades

- El valor de ρ determina cómo varían los p_n :
 - Si $\rho < 1$, los estados más probables son los de menor número de clientes, porque la oferta de servicio supera a la demanda
 - Si $\rho > 1$, los estados más probables son los de mayor número de clientes, porque la demanda de servicio supera a la oferta
 - Si $\rho = 1$, todos los estados son equiprobables, Podemos llegar a la fórmula del caso $\rho = 1$ aplicando la regla de L'Hôpital al límite para $\rho \rightarrow 1$ de la fórmula del caso $\rho \neq 1$
- Si hacemos $M \rightarrow \infty$, llegamos al modelo $M \mid M \mid 1$

Medidas de rendimiento

- Tasa efectiva de llegadas, λ_{ef} , es el número medio de clientes admitidos al sistema por unidad de tiempo de entre los λ que intentan entrar ($\lambda_{ef} < \lambda$):

$$\lambda_{ef} = \lambda(1 - p_M)$$

- Número medio de clientes en el sistema (este valor siempre debe ser inferior a M):

$$L = \begin{cases} \frac{\rho}{1-\rho} - \frac{(M+1)\rho^{M+1}}{1-\rho^{M+1}}, & \text{si } \rho \neq 1 \\ \frac{M}{2}, & \text{si } \rho = 1 \end{cases}$$

Medidas de rendimiento

- Podemos obtener las demás medidas de rendimiento mediante razonamientos ya vistos, teniendo en cuenta que la tasa efectiva de llegadas al sistema es λ_{ef} :

$$W = W_q + \frac{1}{\mu}$$

$$L_q = \lambda_{ef} W_q$$

$$L = \lambda_{ef} W$$

Ejemplo

- A un taller mecánico llegan vehículos para el cambio de pastillas de freno. Los vehículos llegan a un promedio de 18 a la hora según un proceso de Poisson. El espacio físico del taller sólo permite que haya 4 vehículos, y las ordenanzas municipales prohíben esperar fuera. El taller puede servir a un promedio de 6 vehículos por hora.
- Parámetros del sistema: $\lambda = 18$ vehículos/h, $\mu = 6$ vehículos/h, $M = 4$ vehículos

$$\rho = \frac{18}{6} = 3$$

Ejemplo

- ¿Cuál es la probabilidad de que no haya ningún vehículo en el taller?

$$p_0 = \frac{\rho^0(1-\rho)}{1-\rho^{4+1}} = \frac{1-3}{1-3^{4+1}} = \frac{-2}{-242} = \frac{1}{121} \approx 0,00826446$$

- ¿Cuál es el promedio de vehículos que hay en el taller?

$$L = \frac{\rho}{1-\rho} - \frac{(M+1)\rho^{M+1}}{1-\rho^{M+1}} = \frac{3}{1-3} - \frac{(4+1)3^{4+1}}{1-3^{4+1}} =$$
$$\frac{-3}{2} - \frac{1215}{-242} = \frac{426}{121} \approx 3,5206611 \text{ vehículos}$$

Ejemplo

- ¿Cuánto tiempo pasa por término medio un vehículo en el taller?

$$\lambda_{ef} = \lambda(1 - p_M) = \lambda \left(1 - \frac{\rho^M (1 - \rho)}{1 - \rho^{M+1}} \right) =$$

$$18 \left(1 - \frac{3^4 (-2)}{1 - 3^5} \right) = \frac{720}{121} \approx 5,950413 \text{ clientes/h}$$

$$W = \frac{L}{\lambda_{ef}} = \frac{426 / 121}{720 / 121} = \frac{426}{720} = \frac{71}{120} \approx 0,5916666 \text{ horas}$$

Ejemplo

- ¿Cuánto tiempo esperan por término medio en la cola los coches?

$$W_q = W - \frac{1}{\mu} = \frac{71}{120} - \frac{1}{6} = \frac{17}{40} = 0,425 \text{ horas}$$

- ¿Cuál es la longitud media de la cola?

$$L_q = \lambda_{ef} W_q = \frac{720}{121} \cdot \frac{17}{40} = \frac{306}{121} \approx 2,52893 \text{ vehículos}$$